CAK4KBB3 – GENERATIVE AI

MID PROJECT

VIBE CODING GENERATIVE AI FROM SCRATCH

Kode Dosen: MAB



Kelompok: 4

Kelas: IF GAB 02

Anggota:

1. Axel Davin Lazar Panenggak	103012330386
2. Bianka Rosa	103012300335
3. Alexandra Yohana Daris Naibaho	103012330136
4. Sri Dewi Septiani Nur	103012300360

PROGRAM STUDI S1 INFORMATIKA
FAKULTAS INFORMATIKA
TELKOM UNIVERSITY
BANDUNG
2026

IDENTITAS DAN STATUS DOKUMEN

Informasi	Keterangan
Judul proyek	Conditional Generative Adversarial Network (cGAN) bergaya DCGAN pada Fashion-MNIST
Mata kuliah	Generative AI (CAK4KBB3), Mid Project
Kelompok	Kelompok 4 (GEN AI)
Program studi	S1 Informatika, Fakultas Informatika, Telkom University
Framework dan bahasa	PyTorch dan Python
Lingkungan eksekusi	Google Colab dengan GPU NVIDIA T4
Bentuk implementasi	Satu notebook Google Colab (.ipynb), terdiri atas Bagian 0–8
Pendekatan pengerjaan	Vibe Coding dengan bantuan Large Language Model (LLM)
Penanggung jawab dokumentasi	Sri Dewi Septiani Nur
Versi dokumen	Versi final, telah diaudit terhadap tiga notebook (.ipynb) dan arsip hasil eksekusi; Lampiran A disusun per sesi sesuai template panduan
Tahun penyusunan	2026

RINGKASAN EKSEKUTIF

Kelompok mengembangkan Conditional Generative Adversarial Network (cGAN) bergaya DCGAN untuk menghasilkan citra fashion grayscale berukuran 28 × 28 berdasarkan label kelas Fashion-MNIST. Pengembangan dilakukan dari nol menggunakan PyTorch dalam satu notebook Google Colab. Bantuan LLM digunakan untuk menyusun spesifikasi, menjelaskan keputusan arsitektur, menghasilkan kode modular per bagian, merancang pengujian, serta membantu analisis hasil.

Enam kandidat model dibandingkan pada tahap perencanaan. Conditional GAN dipilih karena sesuai dengan keterbatasan waktu sekitar tiga hari, dataset tersedia melalui torchvision, kebutuhan komputasi relatif ringan, hasil dapat diperiksa berdasarkan label kelas, dan pekerjaan dapat dibagi secara jelas kepada empat anggota.

Implementasi dibagi menjadi Bagian 0–2 oleh Axel, Bagian 3–4 oleh Bianka, dan Bagian 5–8 oleh Alexandra, sedangkan Sri mengelola dokumentasi. Baseline training 50 epoch dilaporkan selesai di GPU T4 tanpa error. Evaluasi baseline menunjukkan akurasi classifier pada gambar sintetis sebesar 92,33%, dibandingkan 91,32% pada data asli, serta rasio keragaman minimum 0,92. Eksperimen ablation dengan dropout dan penurunan learning rate Discriminator juga dilakukan.

Hasil metrik classifier menunjukkan kesesuaian label yang tinggi, tetapi tidak dapat ditafsirkan sebagai bukti bahwa gambar sintetis lebih baik daripada gambar asli. Penyebab akurasi sintetis yang sedikit lebih tinggi belum terbukti. Eksperimen hanya menggunakan satu seed per konfigurasi sehingga perbedaan kecil perlu diperlakukan sebagai indikasi, bukan kesimpulan statistik yang kuat. Audit terhadap tiga notebook memastikan bahwa kode dan output eksekusi tersedia untuk seluruh bagian implementasi. Proses kerja didokumentasikan melalui log interaksi per sesi (Lampiran A), daftar tautan bukti (Lampiran B), dan riwayat commit repositori (Subbab 3.6).

DAFTAR ISI

BAB I. PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Tujuan Proyek 1
1.3 Ruang Lingkup Proyek 1
1.4 Pembagian Tugas 2
1.5 Sumber Penyusunan dan Batasan Bukti 2
BAB II. PERENCANAAN DAN SPESIFIKASI PROYEK 3
2.1 Analisis Pemilihan Model 3
2.2 Alasan Pemilihan Conditional GAN 3
2.3 Dataset Fashion-MNIST 4
2.4 Blueprint Arsitektur 4
2.5 Konfigurasi dan Hyperparameter 5
2.6 Kontrak Antarbagian 6
BAB III. IMPLEMENTASI DAN INTERAKSI LLM 8
3.1 Axel: Perencanaan, Setup, Utils, dan Generator 8
3.1.1 Analisis kandidat model 8
3.1.2 Penyusunan cetak biru 8
3.1.3 Bagian 0 dan 1: Setup & Config serta Utils 9
3.1.4 Bagian 2: Generator 9
3.2 Bianka: Dataset, Classifier Pendamping, dan Generate 10
3.2.1 Bagian 3: Dataset 10
3.2.2 Bagian 4: Classifier pendamping 11
3.2.3 Bagian 4: Fungsi generate() 12
3.2.4 Pengujian dan keterbatasan bukti 12
3.3 Alexandra: Discriminator, Training Loop, dan Evaluasi 12
3.3.1 Bagian 5: Discriminator 12
3.3.2 Bagian 6: Training loop 13
3.3.3 Bagian 7: Evaluasi 14
3.3.4 Bagian 8: Eksperimen Ablation 14
3.4 Peran Anggota Dokumentasi 15
3.5 Kendala dan Perbaikan selama Pengerjaan 15
3.6 Bukti Kerja Tim melalui Git 16
BAB IV. HASIL PENGUJIAN DAN EVALUASI 18
4.1 Rekapitulasi Pengujian 18

4.2 Hasil Training Baseline 19
4.3 Evaluasi Model Baseline 20
4.3.1 Evaluasi Akurasi 20
4.3.2 Evaluasi Diversity 21
4.3.3 Confusion Matrix 22
4.3.4 Grid Sampel Gambar Hasil Generate 22
4.3.5 Diagnosis Otomatis Epoch Akhir 23
4.4 Hasil Eksperimen Ablation 23
4.5 Analisis Hasil 25
4.6 Pemilihan Checkpoint untuk Demonstrasi 26
BAB V. AUDIT IMPLEMENTASI DAN BUKTI EKSEKUSI 27
5.1 Berkas yang Diperiksa 27
5.2 Hasil Pemeriksaan Notebook per Anggota 28
5.3 Catatan Error dan Peringatan 28
5.4 Kesesuaian Implementasi dengan Blueprint 29
5.5 Verifikasi Hasil Eksperimen 30
5.6 Catatan Konsistensi dan Batas Bukti 30
5.7 Kesimpulan Audit 31
BAB VI. KESIMPULAN DAN SARAN 32
6.1 Kesimpulan Proyek 32
6.2 Keterbatasan 32
6.3 Saran Pengembangan 33
LAMPIRAN A. LOG INTERAKSI VIBE CODING PER SESI 34
A.1 Anggota 1: Axel (Prompt Engineer) 34
Sesi 1.1: Analisis pemilihan model 34
Sesi 1.2: Penyusunan cetak biru 35
Sesi 1.3: Bagian 0 dan 1 (Setup & Config, Utils) 35
Sesi 1.4: Bagian 2 (Generator) 36
A.2 Anggota 2: Bianka (Data Pipeline) 37
Sesi 2.1: Konfirmasi kontrak Bagian 3–4 37
Sesi 2.2: Bagian 3.1 (get_dataloader) 37
Sesi 2.3: Bagian 3.2 (pemeriksaan visual data) 38
Sesi 2.4: Bagian 4a (classifier pendamping) 39
Sesi 2.5: Bagian 4b (fungsi generate) dan materi serah-terima 40
A.3 Anggota 3: Alexandra (Discriminator, Training Loop, Evaluasi, Ablation) 41

Sesi 3.1: Bagian 5 (Discriminator) 41
Sesi 3.2: Bagian 6 (training loop) 42
Sesi 3.3: Bagian 7 (evaluasi) 42
Sesi 3.4: Bagian 8 (ablation) 43
Sesi 3.5: Interpretasi hasil dan pemilihan checkpoint 44
A.4 Kronologi Lintas Anggota 45
A.5 Status Kelengkapan Log 46
LAMPIRAN B. DAFTAR BUKTI PENDUKUNG 47

DAFTAR TABEL

Tabel 1.1. Pembagian peran dan tanggung jawab anggota kelompok 2
Tabel 2.1. Perbandingan enam kandidat model generatif 3
Tabel 2.2. Spesifikasi dataset Fashion-MNIST 4
Tabel 2.3. Spesifikasi model 5
Tabel 2.4. Konfigurasi dan hyperparameter baseline 6
Tabel 2.5. Kontrak antarmuka tiap bagian notebook 6
Tabel 3.1. Hasil verifikasi Generator 10
Tabel 3.2. Spesifikasi classifier pendamping 11
Tabel 3.3. Hasil pengujian Bagian 5 (Discriminator) 13
Tabel 3.4. Konfigurasi eksperimen ablation 14
Tabel 3.5. Kendala yang dihadapi dan penanganannya 15
Tabel 3.6. Kontribusi anggota pada repositori GEN_AI 16
Tabel 4.1. Rekapitulasi pengujian per bagian notebook 18
Tabel 4.2. Ringkasan loss dan keluaran Discriminator pada training baseline 19
Tabel 4.3. Akurasi classifier dan rasio keragaman per checkpoint baseline 21
Tabel 4.4. Diagnosis otomatis epoch akhir baseline 23
Tabel 4.5. Perbandingan baseline dan eksperimen ablation 24
Tabel 5.1. Berkas notebook yang diperiksa 27
Tabel 5.2. Arsip hasil eksekusi yang diperiksa 27
Tabel 5.3. Ringkasan hasil pemeriksaan notebook per anggota 28
Tabel 5.4. Kesesuaian implementasi dengan blueprint 29
Tabel A.1. Urutan pengerjaan dan serah-terima antaranggota 45
Tabel B.1. Tautan sesi chat LLM dan repositori 47
Tabel B.2. Bukti tambahan yang dapat dilampirkan 47

DAFTAR GAMBAR

Gambar 2.1. Diagram arsitektur dan alur Conditional GAN Fashion-MNIST.....5
Gambar 3.1. Tangkapan layar halaman utama repositori GEN_AI.....17
Gambar 3.2. Tangkapan layar riwayat commit repositori GEN_AI.....17
Gambar 4.1. Kurva loss Generator dan Discriminator selama training baseline.....20
Gambar 4.2. Probabilitas rata-rata D(real) dan D(fake) selama training baseline.....20
Gambar 4.3. Akurasi classifier pada gambar sintetis per checkpoint dan per kelas pada epoch 50 21
Gambar 4.4. Rasio keragaman gambar sintetis terhadap data real per kelas dan per checkpoint 22
Gambar 4.5. Confusion matrix evaluasi checkpoint epoch 50 22
Gambar 4.6. Grid perkembangan sampel gambar dari data real dan checkpoint epoch 1, 10, 25, dan 50.....23
Gambar 4.7. Perbandingan kurva training baseline, run A, dan run B 24
Gambar 4.8. Perbandingan grid sampel epoch 50 pada data real, baseline, run A, dan run B.....25

DAFTAR LAMPIRAN

Lampiran A. Log Interaksi Vibe Coding Per Sesi 34
Lampiran B. Daftar Bukti Pendukung 47

BAB I. PENDAHULUAN

Bab ini menguraikan latar belakang, tujuan, ruang lingkup, serta pembagian tugas dalam proyek pengembangan Conditional Generative Adversarial Network (cGAN) pada dataset Fashion-MNIST.

1.1 Latar Belakang

Generative Adversarial Network (GAN) merupakan pendekatan generatif yang melibatkan dua jaringan saraf, yaitu Generator dan Discriminator, yang dilatih secara adversarial. Generator berupaya menghasilkan data sintetis yang menyerupai data asli, sedangkan Discriminator berupaya membedakan data asli dan data sintetis.

Pada proyek ini digunakan Conditional GAN (cGAN) agar proses generasi tidak hanya bergantung pada noise, tetapi juga pada label kelas. Dengan demikian, model diarahkan untuk menghasilkan citra sesuai kategori Fashion-MNIST, yaitu T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag, dan Ankle boot.

1.2 Tujuan Proyek

- Membangun cGAN bergaya DCGAN dari nol menggunakan PyTorch.
- Menghasilkan citra Fashion-MNIST sintetis berdasarkan label kelas yang diminta.
- Menerapkan data pipeline, Generator, Discriminator, training loop, dan evaluasi dalam satu notebook Colab.
- Memanfaatkan Large Language Model (LLM) sebagai pendamping perancangan hingga debugging melalui Vibe Coding.
- Mendokumentasikan prompt, keputusan teknis, hasil, dan keterbatasan proyek.

1.3 Ruang Lingkup Proyek

Proyek ini mencakup pengembangan cGAN bergaya DCGAN untuk menghasilkan citra grayscale berukuran 28 × 28 berdasarkan label kelas Fashion-MNIST. Seluruh implementasi dikerjakan dari nol menggunakan PyTorch dalam satu notebook Google Colab (.ipynb) yang terdiri atas Bagian 0 sampai Bagian 8,

yaitu setup dan konfigurasi, utilitas, Generator, dataset, classifier pendamping beserta fungsi generate, Discriminator, training loop, evaluasi, dan eksperimen ablation.

Evaluasi model dilakukan melalui training baseline 50 epoch, penilaian menggunakan classifier pendamping yang dibekukan, serta dua eksperimen ablation yang masing-masing mengubah satu pengaturan. Pembagian pekerjaan antaranggota kelompok disajikan pada Subbab 1.4, sedangkan batasan sumber dan bukti dijelaskan pada Subbab 1.5.

1.4 Pembagian Tugas

Peran dan tanggung jawab setiap anggota kelompok dirangkum pada Tabel 1.1.

Tabel 1.1. Pembagian peran dan tanggung jawab anggota kelompok

Anggota	Peran	Tanggung jawab
Axel	Prompt Engineer	Cetak biru, Bagian 0 Setup & Config, Bagian 1 Utils, dan Bagian 2 Generator.
Bianka	Data Pipeline	Bagian 3 Dataset, Bagian 4 Classifier pendamping, dan fungsi generate().
Alexandra	Training Loop	Bagian 5 Discriminator, Bagian 6 Training loop, Bagian 7 Evaluasi, dan Bagian 8 Ablation.
Sri Dewi Septiani Nur	Dokumentasi	Log interaksi LLM, prompt, output, kendala, debugging, hasil pengujian, grafik, dan laporan.

1.5 Sumber Penyusunan dan Batasan Bukti

Dokumen ini disusun dari cetak biru, riwayat percakapan LLM ketiga anggota pengembang, tiga notebook (.ipynb), serta arsip figures, logs, runs, dan ablation yang diserahkan kelompok. Prompt yang sangat panjang diringkas tanpa mengubah tujuan teknisnya. Transkrip verbatim lengkap, tangkapan layar antarmuka Colab.

BAB II. PERENCANAAN DAN SPESIFIKASI PROYEK

Bab ini memuat hasil perencanaan proyek, meliputi analisis pemilihan model, alasan pemilihan Conditional GAN, spesifikasi dataset, blueprint arsitektur, konfigurasi dan hyperparameter, serta kontrak antarbagian notebook.

2.1 Analisis Pemilihan Model

Pada tahap awal, LLM diminta membandingkan enam kandidat model berdasarkan kebutuhan dataset, kesulitan implementasi dari nol, estimasi waktu training pada GPU T4, risiko ketidakstabilan, kemudahan presentasi, dan kemudahan pembagian tugas.

Hasil perbandingan keenam kandidat model dirangkum pada Tabel 2.1.

Tabel 2.1. Perbandingan enam kandidat model generatif

Kandidat	Ringkasan pertimbangan dari analisis awal
Conditional GAN	Dataset gambar berlabel; implementasi rendah–sedang; estimasi awal 5–15 menit untuk 20–30 epoch pada 28×28; risiko mode collapse dan ketidakseimbangan G/D.
Pix2Pix	Membutuhkan data berpasangan; U-Net dan PatchGAN; estimasi awal 1–3 jam pada 256×256.
CycleGAN	Membutuhkan dua domain tak berpasangan; dua Generator dan dua Discriminator; kompleksitas dan waktu training tinggi.
ViT minimalis / MAE	Dapat memakai dataset gambar kecil, tetapi formulasi rekonstruksi patch dinilai kurang langsung sebagai generasi dari noise.
Mini Diffusion Model	Memerlukan U-Net kecil, time embedding, noise schedule, serta proses sampling; estimasi awal 30–90 menit.
MiniTransformer GPT	Cocok untuk teks, bukan dataset gambar Fashion-MNIST; membutuhkan korpus teks.

2.2 Alasan Pemilihan Conditional GAN

Rekomendasi awal adalah Conditional GAN pada Fashion-MNIST. Pertimbangan utamanya ialah kesesuaian dengan waktu pengerjaan sekitar tiga hari, ketersediaan dataset pada torchvision, kebutuhan komputasi yang relatif

ringan, kemudahan memeriksa hasil berdasarkan label, serta pembagian tanggung jawab yang jelas bagi empat anggota.

Dua risiko utama yang dicatat pada analisis awal adalah mode collapse atau ketidakseimbangan Generator dan Discriminator, serta interpretasi kurva loss GAN yang tidak selalu menurun secara monoton (lihat Subbab 3.1.1).

2.3 Dataset Fashion-MNIST

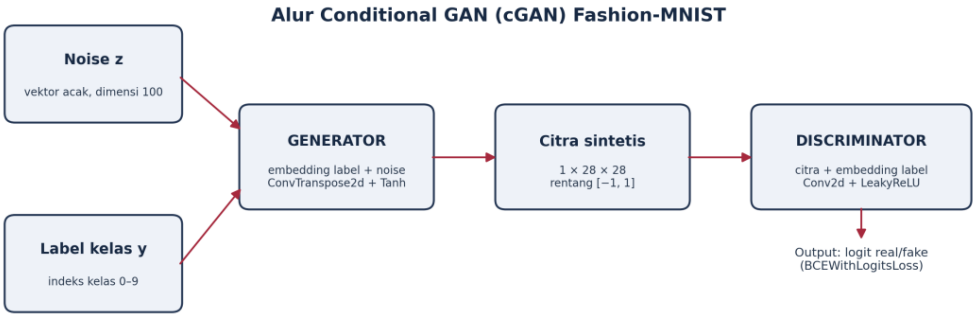
Dataset yang digunakan adalah Fashion-MNIST yang tersedia melalui torchvision. Dataset terdiri atas 60.000 gambar train dan 10.000 gambar test berukuran 28 × 28 piksel dengan satu kanal grayscale, mencakup sepuluh kelas, yaitu T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag, dan Ankle boot. Spesifikasi dataset ditunjukkan pada Tabel 2.2.

Tabel 2.2. Spesifikasi dataset Fashion-MNIST

Parameter	Nilai acuan proyek
Dataset	Fashion-MNIST
Jumlah data train/test	60.000 / 10.000 gambar
Resolusi dan kanal	28 × 28, grayscale (1 kanal)
Jumlah kelas	10
Normalisasi	[−1, 1]

2.4 Blueprint Arsitektur

Alur kerja Conditional GAN yang dirancang ditunjukkan pada Gambar 2.1. Vektor noise z berdimensi 100 dan label kelas y berupa indeks 0–9 menjadi masukan Generator. Generator menghasilkan citra sintetis berukuran 1 × 28 × 28 pada rentang [−1, 1], yang kemudian dinilai Discriminator bersama embedding label. Keluaran Discriminator berupa logit real/fake yang digunakan pada BCEWithLogitsLoss.



Gambar 2.1. Diagram arsitektur dan alur Conditional GAN Fashion-MNIST

Spesifikasi model yang tercatat pada cetak biru dan hasil pengujian implementasi dirangkum pada Tabel 2.3.

Tabel 2.3. Spesifikasi model

Komponen	Spesifikasi yang tercatat
Generator	Masukan z [B,100] dan y [B]; embedding label digabungkan (concatenate) dengan noise; resolusi dibangun dari 7×7 melalui ConvTranspose2d hingga 28×28; aktivasi Tanh pada keluaran; keluaran [B,1,28,28] pada rentang [−1,1]; 1.105.877 parameter.
Discriminator	Masukan x [B,1,28,28] dan y [B]; label dibentuk melalui Embedding(10,784) menjadi peta 1×28×28 dan digabungkan dengan gambar menjadi [B,2,28,28]; tiga convolution stride 2 dengan LeakyReLU 0,2; Flatten; Linear(4096,1); keluaran logit [B] tanpa Sigmoid; dropout dan spectral norm tersedia dengan pengaturan awal nonaktif; 440.801 parameter.
Fungsi loss dan target	BCEWithLogitsLoss; target real 0,9 (one-sided label smoothing), target fake 0,0, dan target Generator 1,0.
Classifier pendamping	Dilatih pada data asli selama 5 epoch lalu dibekukan; spesifikasi lengkap pada Tabel 3.2.

2.5 Konfigurasi dan Hyperparameter

Konfigurasi dan hyperparameter baseline ditetapkan sejak cetak biru dan dirangkum pada Tabel 2.4.

Tabel 2.4. Konfigurasi dan hyperparameter baseline

Parameter	Nilai acuan proyek
Batch size	128
Iterasi per epoch	468 batch (drop_last pada data train)
Dimensi noise	100
Epoch baseline	50
Optimizer	Adam
Learning rate G dan D	2×10^{-4}
Betas	(0,5; 0,999)
Target real / fake / G	0,9 / 0,0 / 1,0
Seed	42

2.6 Kontrak Antarbagian

Notebook dibagi menjadi sembilan bagian (Bagian 0–8) dengan kontrak antarmuka yang ditetapkan sejak cetak biru, sehingga setiap anggota dapat bekerja pada bagiannya tanpa menunggu bagian lain selesai.

Kontrak antarmuka setiap bagian notebook ditunjukkan pada Tabel 2.5.

Tabel 2.5. Kontrak antarmuka tiap bagian notebook

Bagian	Pemilik	Kontrak antarmuka
0 Setup & Config	Axel	CFG, hyperparameter, seed, DEVICE.
1 Utils	Axel	weights_init, denormalize, make_fixed_noise, save_image_grid, show_image_grid, checkpoint.
2 Generator	Axel	G(z [B,100], y [B]) menghasilkan gambar [B,1,28,28] dalam rentang [−1,1].
3 Dataset	Bianka	get_dataloader(batch_size) menghasilkan gambar [B,1,28,28] float32 [−1,1] dan label [B] int64 0–9.
4 Classifier + Generate	Bianka	Classifier: gambar [B,1,28,28] → logit [B,10]; generate(checkpoint, class_id, n) menghasilkan gambar kelas tertentu.

Bagian	Pemilik	Kontrak antarmuka
5 Discriminator	Alexandra	D(x [B,1,28,28], y [B]) menghasilkan logit [B] tanpa Sigmoid.
6 Training loop	Alexandra	Loop G/D, checkpoint, log CSV per iterasi dan per epoch.
7 Evaluasi	Alexandra	Grid sampel, akurasi classifier pendamping, kurva, dan metrik dari file log.
8 Ablation	Alexandra	Eksperimen pembanding dengan satu perubahan per run dan folder keluaran terpisah.
Dokumentasi	Sri	Prompt, jawaban LLM, error, perbaikan, serta grafik hasil.

BAB III. IMPLEMENTASI DAN INTERAKSI LLM

Bab ini merangkum alur interaksi dengan LLM berdasarkan urutan pengembangan. Kutipan prompt merupakan inti instruksi yang tercatat dalam riwayat percakapan. Hasil kuantitatif training dan evaluasi disajikan pada Bab IV.

Ringkasan interaksi per anggota disajikan pada bab ini, sedangkan log interaksi per sesi yang lebih rinci terdapat pada Lampiran A. Ringkasan tersebut bukan transkrip lengkap percakapan.

3.1 Axel: Perencanaan, Setup, Utils, dan Generator

Anggota 1 (Axel) berperan sebagai Prompt Engineer. Tujuan penggunaan LLM adalah menganalisis pemilihan model, menyusun cetak biru teknis, serta mengimplementasikan Bagian 0, Bagian 1, dan Bagian 2 secara bertahap dengan pola konsep, kode, dan tes.

3.1.1 Analisis kandidat model

Prompt utama

> *"Buat analisis perbandingan enam kandidat model generatif: Conditional GAN, Pix2Pix, CycleGAN, Vision Transformer minimalis, Mini Diffusion Model, dan Mini-Transformer GPT. Bandingkan kebutuhan dataset, kesulitan implementasi dari nol, estimasi training di GPU T4, risiko, kemudahan presentasi, dan pembagian empat peran."*

Output LLM merekomendasikan Conditional GAN pada Fashion-MNIST. Dua risiko utama yang dicatat adalah mode collapse atau ketidakseimbangan Generator dan Discriminator, serta interpretasi kurva loss GAN yang tidak selalu menurun secara monoton. Mitigasi yang diusulkan mencakup arsitektur DCGAN, Adam, one-sided label smoothing, checkpoint, grid sampel berkala, metrik D(real)/D(fake), dan classifier pendamping.

3.1.2 Penyusunan cetak biru

Prompt utama

> *"Susun cetak biru Conditional GAN untuk Fashion-MNIST dari nol dengan PyTorch. Jabarkan preprocessing, arsitektur Generator dan*

Discriminator, formulasi loss, hyperparameter, stabilisasi, evaluasi, alur generate, dan risiko."

Cetak biru menjadi acuan teknis bersama. Dalam revisi final, kelompok menetapkan implementasi menggunakan satu notebook Colab (.ipynb), bukan file Python terpisah. Setiap bagian ditempatkan dalam cell dengan judul Markdown yang jelas dan berbagi variabel melalui konfigurasi.

3.1.3 Bagian 0 dan 1: Setup & Config serta Utils

Prompt implementasi

"Buat Bagian 0 dan 1 sesuai cetak biru: import, seed, device, seluruh hyperparameter dalam satu konfigurasi; kemudian weight initialization, penyimpanan grid gambar dengan denormalisasi, serta simpan/muat checkpoint ke Google Drive. Jelaskan konsep, alasan desain, kode, cara tes, dan pertanyaan yang mungkin diajukan dosen."

Notebook Bagian 0–1 dilaporkan lulus tes lokal dari atas ke bawah. Pada tahap tersebut, GPU T4 dan proses mount Google Drive belum teruji di lingkungan lokal. Setelah dijalankan di Colab, anggota melaporkan Bagian 0–1 lulus pada GPU T4.

Utilitas tambahan yang tercatat meliputi make_fixed_noise untuk grid 10×10 yang konsisten, ckpt_path dan latest_checkpoint untuk resume, penyimpanan checkpoint secara atomik, dan fallback ke folder lokal jika Drive tidak tersedia.

3.1.4 Bagian 2: Generator

Prompt implementasi

"Implementasikan Generator sesuai cetak biru. Ukuran layer harus dibaca dari CFG; gunakan weights_init; uji output [B,1,28,28] dalam rentang [−1,1], jumlah parameter sekitar 1,1 juta, pengaruh label terhadap output, batch satu sampel dalam mode eval, dan grid fixed-noise."

Generator menggunakan embedding label yang digabungkan (concatenate) dengan noise. Resolusi dibangun dari ukuran awal 7×7 dan dinaikkan melalui ConvTranspose2d hingga 28×28. Fungsi aktivasi Tanh digunakan pada keluaran agar rentang gambar sesuai normalisasi data.

Tabel 3.1. Hasil verifikasi Generator

Aspek yang diuji	Hasil yang dilaporkan
Jumlah parameter	1.105.877 (sekitar 1,1 juta).
Output	[B,1,28,28] dan rentang [−1,1].
Efek label	Noise z yang sama dengan label berbeda menghasilkan gambar berbeda.
Batch kecil	Batch satu sampel dalam mode eval dapat dijalankan.
Tes tambahan	Gradien embedding dan pemanggilan weights_init diperiksa; bug yang sengaja ditanam dapat dideteksi.

Catatan interpretasi. Generator yang belum dilatih dapat terlihat abu-abu rata dalam mode eval karena statistik berjalan BatchNorm masih berada pada nilai awal. Kondisi ini merupakan perilaku awal sebelum statistik BatchNorm terbentuk, bukan otomatis kerusakan model.

3.2 Bianka: Dataset, Classifier Pendamping, dan Generate

Anggota 2 (Bianka) berperan sebagai Data Pipeline. LLM digunakan untuk mengimplementasikan Bagian 3 (Dataset) dan Bagian 4 (Classifier pendamping dan fungsi generate) dengan menggunakan ulang konfigurasi, utilitas, dan Generator dari bagian sebelumnya.

3.2.1 Bagian 3: Dataset

Prompt awal

> *"Bertindak sebagai Senior Machine Learning Engineer PyTorch. Saya mengerjakan Bagian 3 Dataset dan Bagian 4 Classifier pendamping + generate. Gunakan ulang CFG, DEVICE, CLASS_NAMES, fungsi utilitas, checkpoint, dan Generator dari notebook tim. Bekerja bertahap dengan pola konsep → kode → tes; jangan lanjut sebelum tes dikonfirmasi."*

Kontrak DataLoader adalah batch gambar [B,1,28,28] float32 dengan rentang [−1,1] dan label [B] int64 pada rentang 0–9. Data train menggunakan shuffle=True dan drop_last=True sehingga terdapat 468 batch per epoch untuk batch size 128. Split test digunakan untuk evaluasi classifier dengan shuffle=False dan drop_last=False.

Transformasi menggunakan ToTensor() kemudian Normalize(CFG.norm_mean, CFG.norm_std), tanpa augmentasi. Label tetap berupa indeks kelas, bukan one-hot, agar kompatibel dengan embedding pada Generator dan Discriminator.

Bianka mengusulkan get_dataloader(batch_size, train=True) agar pemanggilan train standar tetap kompatibel, sedangkan train=False digunakan untuk memuat seluruh data test. Untuk konfigurasi classifier, dibuat dataclass terpisah ClassifierConfig atau CLF_CFG agar CFG milik ketua tidak diubah.

3.2.2 Bagian 4: Classifier pendamping

Classifier berfungsi sebagai alat ukur independen untuk menilai apakah gambar yang dihasilkan Generator dikenali sesuai label yang diminta. Model dilatih pada gambar Fashion-MNIST asli, lalu dibekukan agar bobotnya tidak berubah selama evaluasi GAN.

Tabel 3.2. Spesifikasi classifier pendamping

Komponen	Spesifikasi yang tercatat
Arsitektur	Conv(1→32, k=3, padding=1) – ReLU – MaxPool; Conv(32→64, k=3, padding=1) – ReLU – MaxPool; Flatten; Linear(3136→128) – ReLU; Linear(128→10).
Ukuran fitur	28×28 → 14×14 → 7×7; Flatten = 64×7×7 = 3136.
Loss dan optimizer	CrossEntropyLoss dan Adam dengan learning rate 1e-3.
Training	5 epoch pada data asli, batch size memakai CFG.batch_ size.
Keluaran	Logit [B,10] tanpa softmax.
Status akhir	eval() dan requires_grad=False; bobot disimpan sebagai classifier.pt.

Keputusan padding=1 diambil karena cetak biru tidak menetapkan padding secara eksplisit. Padding tersebut mempertahankan ukuran spasial pada convolution sehingga MaxPool menghasilkan urutan resolusi 28→14→7, konsisten dengan rancangan Generator dan Discriminator.

3.2.3 Bagian 4: Fungsi generate()

Fungsi generate(checkpoint, class_id, n) memuat bobot Generator dari checkpoint, mengatur model ke mode eval, membuat noise acak berdimensi CFG.z_dim, membentuk label kelas sebanyak n, dan menghasilkan gambar di bawah torch.no_grad(). Output tetap pada rentang [−1,1] dan tidak didenormalisasi agar sesuai dengan fungsi save_image_grid.

Validasi yang dirancang mencakup kesesuaian konfigurasi checkpoint dengan CFG, validasi class_id pada rentang kelas, n lebih besar dari nol, bentuk output, rentang nilai, serta seed opsional agar demonstrasi dapat diulang.

3.2.4 Pengujian dan keterbatasan bukti

Riwayat yang tersedia mencatat tes arsitektur classifier, bentuk logit, jumlah parameter, aliran gradien, input tidak valid, pembekuan model, simpan–muat bobot, dan mekanisme melewati training jika file classifier sudah tersedia. Sebagian pengujian awal dilakukan di sandbox menggunakan data pengganti karena unduhan Fashion-MNIST tidak tersedia di lingkungan tersebut. Hasil kualitas dan akurasi pada dataset asli harus mengacu pada eksekusi Colab, bukan hasil data pengganti.

3.3 Alexandra: Discriminator, Training Loop, dan Evaluasi

Anggota 3 (Alexandra) berperan sebagai Training Loop. LLM digunakan untuk mengimplementasikan Bagian 5 (Discriminator), Bagian 6 (Training loop), Bagian 7 (Evaluasi), serta Bagian 8 (Ablation).

3.3.1 Bagian 5: Discriminator

Prompt implementasi

> *"Implementasikan Discriminator D(x [B,1,28,28], y [B]) yang menghasilkan logit [B] tanpa Sigmoid. Ubah label melalui nn.Embedding(10,784), reshape menjadi 1×28×28, gabungkan dengan gambar, ikuti tabel layer cetak biru, inisialisasi N(0,0.02), dan sediakan opsi dropout serta spectral_norm yang default-nya mati."*

Discriminator menggabungkan gambar dan peta embedding label sebagai dua kanal masukan. Arsitektur menggunakan tiga convolution stride 2, LeakyReLU 0,2, flatten, dan linear output satu logit per gambar. Sigmoid tidak digunakan pada model karena fungsi loss yang direncanakan adalah BCEWithLogitsLoss.

Tabel 3.3. Hasil pengujian Bagian 5 (Discriminator)

Pengujian	Hasil yang dilaporkan
Jumlah parameter	440.801 parameter.
Bentuk keluaran	Logit [B] float32 tanpa Sigmoid.
Embedding label	Embedding(10,784), dibentuk menjadi peta 1×28×28.
Tes pasangan label	Logit pasangan gambar–label benar dan label salah berbeda.
Mini-training	Setelah 150 langkah, pasangan benar dinilai lebih tinggi daripada pasangan salah pada 100% pasangan.
Tes tambahan	Dropout, spectral norm, gradien ke gambar, simpan–muat, dan input salah dilaporkan lulus.

Tiga keputusan desain disepakati: embedding Discriminator menggunakan inisialisasi default PyTorch mengikuti konvensi tim; convolution pada mode spectral norm diberi bias ketika BatchNorm dihilangkan; dan weights_init tidak dipanggil ulang pada Bagian 6 karena inisialisasi telah dilakukan di konstruktor.

3.3.2 Bagian 6: Training loop

Prompt implementasi

> *"Buat training loop 50 epoch sesuai cetak biru menggunakan BCEWithLogitsLoss, target real 0,9, fake 0,0, dan target Generator 1,0. Gunakan dua optimizer Adam terpisah untuk G dan D, satu langkah D lalu satu langkah G per iterasi, detach pada fake saat update D, noise baru setiap iterasi, checkpoint tiap 10 epoch dan akhir, CSV per iterasi/per epoch, grid sampel epoch 1 dan setiap 5 epoch, serta fungsi resume. Sertakan smoke test sebelum training penuh."*

Dalam setiap iterasi, Generator membuat gambar palsu dari noise baru dan label dari batch real. Discriminator dilatih untuk memberi target 0,9 pada pasangan real dan 0,0 pada pasangan fake. Gambar fake di-detach pada langkah ini agar gradien tidak memperbarui Generator. Selanjutnya Generator dilatih agar Discriminator memberi target 1,0 pada gambar palsu; pada langkah Generator, gradien harus mengalir kembali ke Generator.

Target real 0,9 merupakan one-sided label smoothing untuk mengurangi kecenderungan Discriminator terlalu yakin. Loss Discriminator merupakan

penjumlahan komponen real dan fake yang masing-masing dirata-ratakan atas batch.

Implementasi yang dilaporkan mencakup train_iter.csv dan train_epoch.csv, checkpoint setiap 10 epoch serta epoch akhir, grid sampel tetap, resume dari checkpoint, validasi konfigurasi, serta penghentian jika loss menjadi NaN. Smoke test menggunakan run kecil dan folder sementara sebelum training penuh.

3.3.3 Bagian 7: Evaluasi

Evaluasi memakai classifier pendamping yang dibekukan dan fungsi generate() milik Bianka. Pengukuran dilakukan pada checkpoint epoch 10, 20, 30, 40, dan 50. Metrik mencakup akurasi classifier pada gambar sintetis, akurasi classifier pada data asli, rasio keragaman sintetis terhadap real per kelas, kurva loss, D(real)/D(fake), confusion matrix, dan grid sampel.

Grafik dibuat dari file log/CSV, bukan dari angka yang diketik manual. Grid sampel dari epoch awal, tengah, dan akhir digunakan untuk membandingkan perubahan kualitas visual. Evaluasi memakai seed berbeda dari seed grid agar hasil evaluasi tidak identik dengan contoh visual tetap.

3.3.4 Bagian 8: Eksperimen Ablation

Setelah baseline memenuhi target evaluasi, dua eksperimen ablation dilakukan dengan satu perubahan per run dan folder keluaran terpisah. Tujuannya adalah memeriksa apakah melemahkan Discriminator mengubah keseimbangan loss dan nilai D(fake). Hasil kedua eksperimen disajikan pada Subbab 4.4.

Tabel 3.4. Konfigurasi eksperimen ablation

Run	Perubahan dari baseline	Tujuan
Baseline	Tidak ada	Acuan pembanding (konfigurasi pada Tabel 2.4).
A	d_dropout = 0,3	Menambah dropout pada Discriminator untuk melemahkannya.
B	lr_d = 1e-4	Menurunkan learning rate Discriminator dari 2×10^{-4}.

3.4 Peran Anggota Dokumentasi

Sri Dewi Septiani Nur bertanggung jawab atas dokumentasi proyek. Tugasnya mencakup pengelolaan log interaksi LLM, prompt, output, kendala, proses debugging, hasil pengujian, grafik, dan penyusunan laporan. Dalam urutan pengerjaan, dokumentasi menggabungkan cetak biru, log interaksi, kode, grafik, dan hasil yang diserahkan ketiga anggota pengembang menjadi laporan proyek dan bukti proses Vibe Coding (lihat Tabel A.1 pada Lampiran A).

3.5 Kendala dan Perbaikan selama Pengerjaan

Kendala yang terdokumentasi selama pengerjaan beserta keputusan atau perbaikannya dirangkum pada Tabel 3.5. Rincian per sesi terdapat pada kolom Tahap Penanganan Eror di Lampiran A.

Tabel 3.5. Kendala yang dihadapi dan penanganannya

Tahap	Kendala / ketidakjelasan	Keputusan atau penanganan
Cetak biru → implementasi	Rancangan awal menyebut file .py terpisah, tetapi tim memilih satu notebook Colab.	Cetak biru direvisi agar pembagian berbasis Bagian notebook dan kontrak tensor.
Generator awal	Generator belum dilatih tampak abu-abu dalam mode eval.	Dijelaskan sebagai efek statistik BatchNorm yang belum terisi; bukan langsung dianggap bug.
Classifier	Cetak biru tidak menetapkan padding convolution.	Dipilih padding=1 agar resolusi menjadi 28→14→7 dan flatten 3136.
Konfigurasi classifier	CFG dikelola anggota lain dan tidak boleh diubah.	Dibuat ClassifierConfig/CLF_ CFG terpisah.
Checkpoint classifier	Nama file dapat tertangkap mekanisme pencarian checkpoint GAN.	Nama classifier.pt dipilih agar tidak berbenturan dengan pola ckpt_epoch.
Mount Drive (Bagian 3.2)	Mount Google Drive gagal (“credential propagation was unsuccessful”) sehingga keluaran tersimpan di ./outputs.	Ditambahkan sel drive.mount() di awal notebook; keluaran pindah ke folder Drive kelompok.

Tahap	Kendala / ketidakjelasan	Keputusan atau penanganan
Discriminator	Perbedaan spesifikasi bias pada mode spectral norm dan inisialisasi embedding.	Keputusan desain dikonfirmasi sebelum training; embedding memakai default PyTorch dan bias dipertahankan saat BatchNorm dihilangkan.
Training resume	Optimizer checkpoint dapat memuat learning rate lama.	Learning rate optimizer ditimpa dari CFG saat resume agar perubahan lr_d berlaku.
Akurasi sintetis > real	Penjelasan awal "prototipikal" tidak didukung uji keyakinan.	Kesimpulan dikoreksi: penyebab selisih belum terbukti.

3.6 Bukti Kerja Tim melalui Git

Kerja tim didokumentasikan melalui repositori GitHub kelompok (tautan pada Lampiran B). Pembagian peran dan urutan serah-terima antaranggota ditunjukkan pada Tabel A.1 (Lampiran A), sedangkan subbab ini menghubungkannya dengan riwayat commit pada repositori.

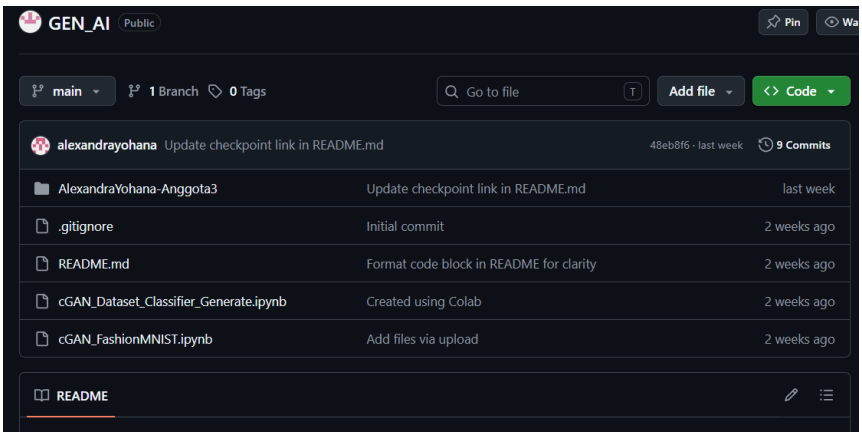
Berdasarkan tangkapan layar halaman utama repositori, repositori GEN_AI berstatus publik, memiliki satu branch (main), belum memiliki tag, dan mencatat 9 commit. Commit terakhir (48eb8f6) berpesan "Update checkpoint link in README.md" dan dilakukan oleh akun alexandrayohana.

Tabel 3.6. Kontribusi anggota pada repositori GEN_AI

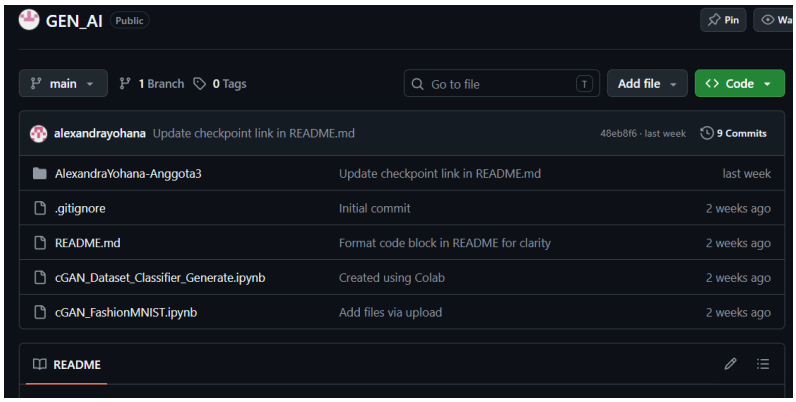
Anggota	Kontribusi	Berkas di repositori	Bukti commit
Axel	Bagian 0–2 (Setup & Config, Utils, Generator)	`cGAN_FashionMNIST.ipynb`	Pesan commit "Add files via upload".
Bianka	Bagian 3–4 (Dataset, Classifier, generate)	`cGAN_Dataset_Classifier_Generate.ipynb`	Pesan commit "Created using Colab".

Anggota	Kontribusi	Berkas di repositori	Bukti commit
Alexandra	Bagian 5–8 (Discriminator, Training Loop, Evaluasi, Ablation)	Folder `AlexandraYohana-Anggota3`, pembaruan `README.md`	Commit oleh akun alexandrayohana, termasuk 48eb8f6 “Update checkpoint link in README.md”.
Sri	Dokumentasi dan pengelolaan repositori	`.gitignore`, `README.md`	Pesan commit “Initial commit” dan “Format code block in README for clarity”.

Gambar 3.1. Tangkapan layar halaman utama repositori GEN_AI



Gambar 3.2. Tangkapan layar riwayat commit (tab Commits) yang memperlihatkan akun dan tanggal tiap commit.



Tabel di atas menyatakan keterkaitan berkas dengan anggota berdasarkan pembagian tugas pada Tabel 1.1.

BAB IV. HASIL PENGUJIAN DAN EVALUASI

Bab ini menyajikan rekapitulasi pengujian, hasil training baseline, evaluasi model, hasil eksperimen ablation, serta analisis hasil. Seluruh angka dan grafik berasal dari bahan proyek yang diserahkan kelompok.

4.1 Rekapitulasi Pengujian

Output notebook memperlihatkan TES BAGIAN 0, TES 1.1–1.4, TES 2.1–2.6, TES 3.1, TES 3.2, TES 4a.1, TES 4a.2, TES 4b, TES 5, TES 6, TES 7, dan TES 8 berstatus LULUS pada eksekusi yang tersimpan. TES 3.2 juga mencantumkan bahwa pemeriksaan visual manual tetap perlu dilakukan.

Rekapitulasi status pengujian setiap bagian notebook ditunjukkan pada Tabel 4.1.

Tabel 4.1. Rekapitulasi pengujian per bagian notebook

Bagian	Pengujian / indikator	Status berdasarkan output notebook
Bagian 0–1	Setup, konfigurasi, utilitas, checkpoint	TES 0 dan TES 1.1–1.4 lulus; dikonfirmasi di Colab T4 dengan Google Drive terhubung.
Bagian 2	Bentuk/rentang output, parameter, efek label, batch 1	TES 2.1–2.6 lulus; 1.105.877 parameter.
Bagian 3	Bentuk tensor, dtype, rentang, split train/test, visualisasi	TES 3.1 dan TES 3.2 lulus; pemeriksaan visual manual tetap diperlukan.
Bagian 4	Classifier, evaluasi, freeze, simpan–muat, generate	TES 4a.1, 4a.2, dan 4b lulus; akurasi test classifier 91,47% (notebook Bianka).
Bagian 5	Logit, parameter, pasangan label, mode opsional	TES 5 lulus di Colab; 440.801 parameter.
Bagian 6	Smoke test, detach, optimizer, loss, CSV, checkpoint, resume	TES 6 lulus; training baseline 50 epoch selesai di Colab T4.
Bagian 7	Grafik, akurasi sintetis, keragaman, diagnosis	TES 7 lulus; seluruh metrik baseline memenuhi ambang akurasi dan keragaman.

Bagian	Pengujian / indikator	Status berdasarkan output notebook
Bagian 8	Ablation run A dan B	TES 8 lulus; kedua run selesai dan tabel perbandingan tersimpan.

4.2 Hasil Training Baseline

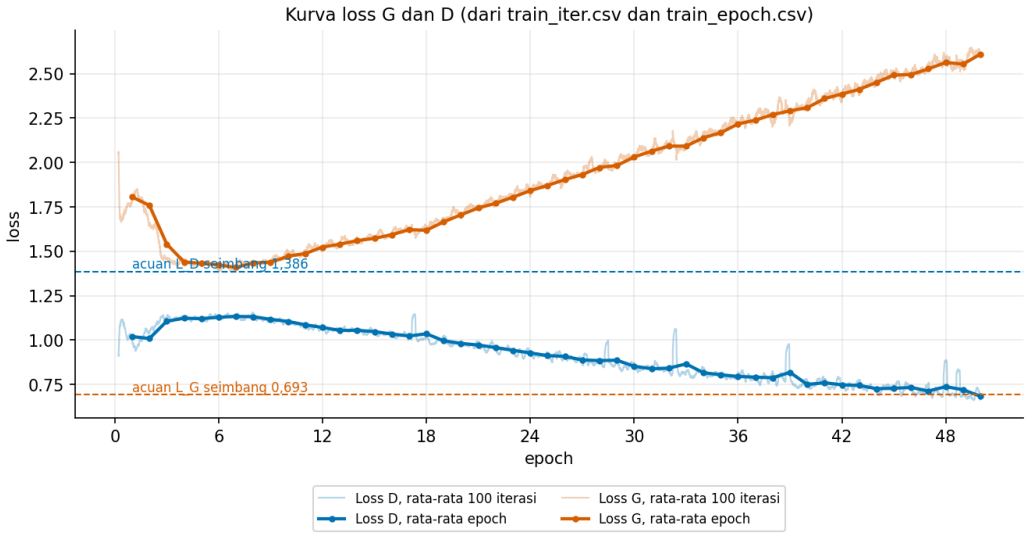
Training baseline 50 epoch dilaporkan selesai di Colab dengan GPU T4 tanpa error, sekitar 18 detik per epoch atau sekitar 15 menit keseluruhan. Checkpoint tersedia pada epoch 10, 20, 30, 40, dan 50. Berdasarkan train_epoch.csv, epoch terakhir mencatat LG = 2,610, LD = 0,684, D(real) = 0,735, dan D(fake) = 0,164, dengan waktu epoch terakhir 18,6 detik.

Ringkasan nilai loss dan keluaran Discriminator pada beberapa epoch ditunjukkan pada Tabel 4.2.

Tabel 4.2. Ringkasan loss dan keluaran Discriminator pada training baseline

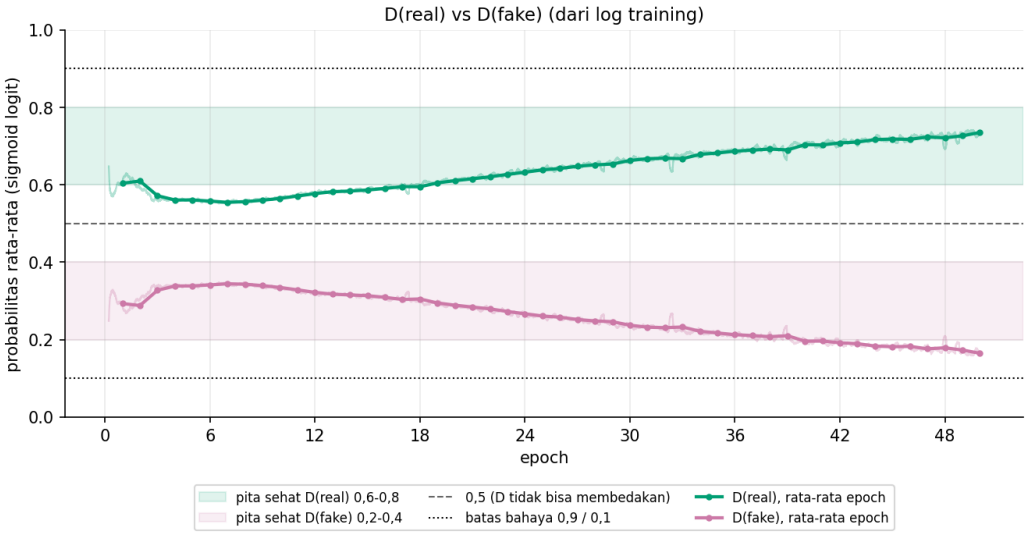
Epoch	LG	LD	D(real)	D(fake)	Catatan
1	1,806	1,020	0,604	0,293	Awal training.
10	1,472	1,105	–	–	Checkpoint tersimpan.
25	1,871	0,913	–	–	Titik ringkasan yang dilaporkan.
50	2,610	0,684	0,735	0,164	Checkpoint akhir.

Kurva loss Generator dan Discriminator selama training baseline ditampilkan pada Gambar 4.1.



Gambar 4.1. Kurva loss Generator dan Discriminator selama training baseline.

Tren ringkasan memperlihatkan LD menurun dan LG meningkat. Hal ini dibahas sebagai dinamika kompetisi antara G dan D, bukan dinilai sendirian sebagai kegagalan. Gambar 4.2 memperlihatkan bahwa D(real) naik dan D(fake) turun secara bertahap selama training.



Gambar 4.2. Probabilitas rata-rata D(real) dan D(fake) selama training baseline.

4.3 Evaluasi Model Baseline

4.3.1 Evaluasi Akurasi

Evaluasi dilakukan pada lima checkpoint (epoch 10–50) menggunakan classifier pendamping yang dibekukan. Akurasi classifier pada data asli sebagai pembanding adalah 91,32%.

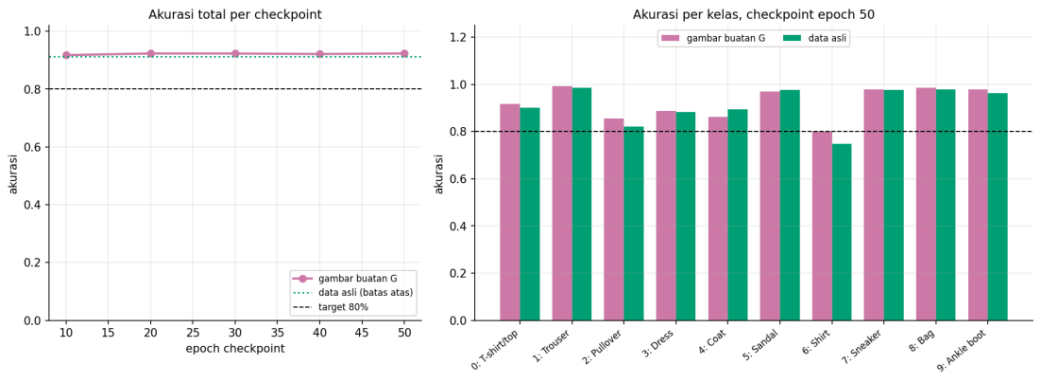
Hasil evaluasi akurasi classifier dan rasio keragaman pada kelima checkpoint dirangkum pada Tabel 4.3.

Tabel 4.3. Akurasi classifier dan rasio keragaman per checkpoint baseline

Epoch	Akurasi gambar buatan	Akurasi data real	Rasio keragaman min.	Kelas rasio min.
10	91,75%	91,32%	0,856	Trouser
20	92,32%	91,32%	0,830	Trouser
30	92,30%	91,32%	0,888	Trouser
40	92,13%	91,32%	0,874	Trouser
50	92,33%	91,32%	0,918	Trouser

Pada epoch 50, kelas dengan akurasi terendah adalah Shirt sebesar 80,00% (pembanding data asli 74,90%), sedangkan tertinggi adalah Trouser sebesar 99,20%. Rasio keragaman minimum epoch 50 sebesar 0,918 (dibulatkan menjadi 0,92) dengan kelas minimum Trouser, dan seluruh checkpoint berada di atas ambang 0,5. Metrik classifier ini mengukur kesesuaian label, bukan keseluruhan kualitas visual atau realisme gambar.

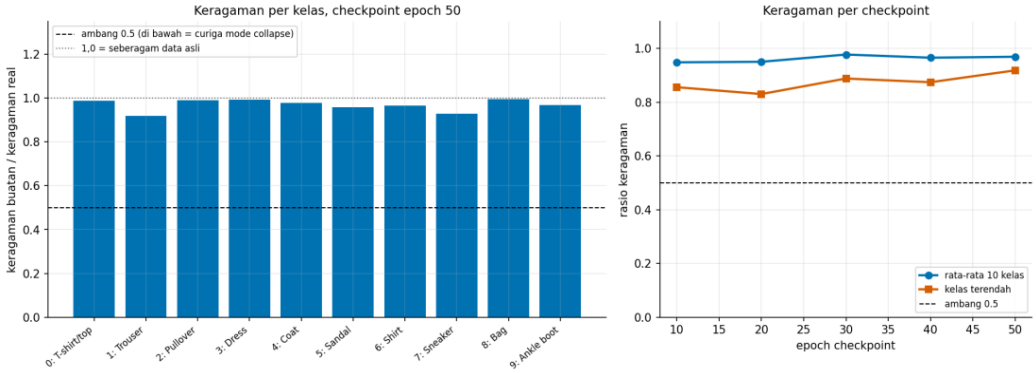
Perkembangan akurasi per checkpoint dan akurasi per kelas pada epoch 50 ditunjukkan pada Gambar 4.3.



Gambar 4.3. Akurasi classifier pada gambar sintetis per checkpoint (kiri) dan per kelas pada epoch 50 (kanan).

4.3.2 Evaluasi Diversity

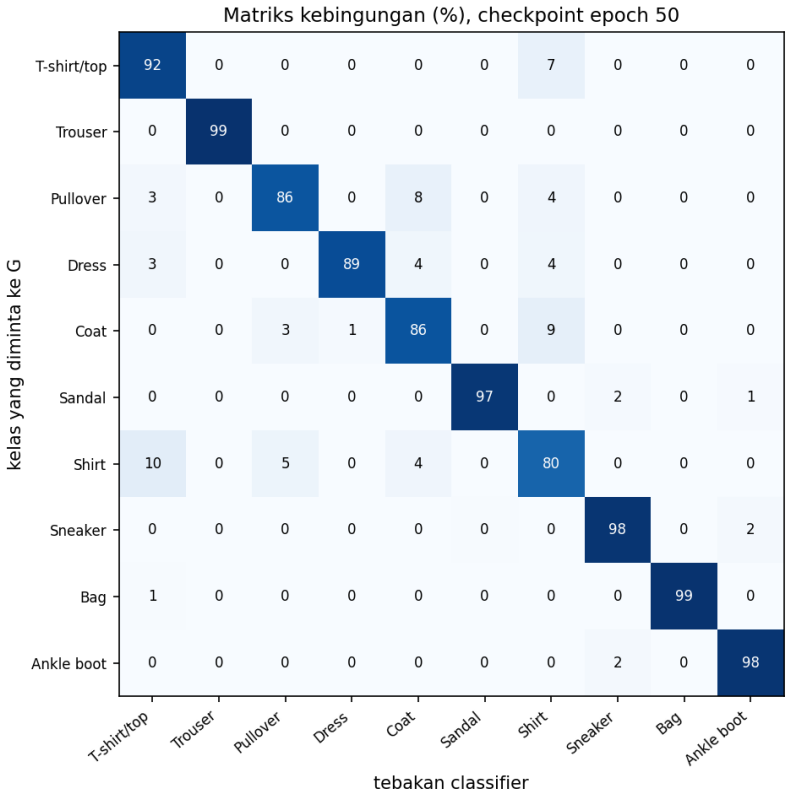
Rasio keragaman gambar sintetis terhadap data real per kelas dan per checkpoint ditunjukkan pada Gambar 4.4.



Gambar 4.4. Rasio keragaman gambar sintetis terhadap data real per kelas pada epoch 50 (kiri) dan per checkpoint (kanan).

4.3.3 Confusion Matrix

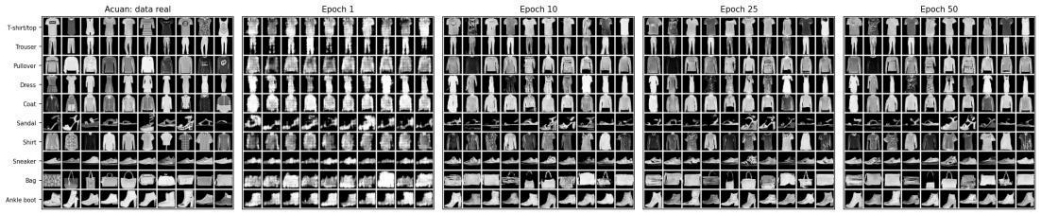
Confusion matrix evaluasi checkpoint epoch 50 ditampilkan pada Gambar 4.5.



Gambar 4.5. Confusion matrix evaluasi checkpoint epoch 50.

4.3.4 Grid Sampel Gambar Hasil Generate

Perkembangan kualitas visual gambar yang dihasilkan, dibandingkan dengan data real, ditunjukkan pada Gambar 4.6.



Gambar 4.6. Grid perkembangan sampel gambar dari data real dan checkpoint epoch 1, 10, 25, dan 50.

4.3.5 Diagnosis Otomatis Epoch Akhir

Diagnosis otomatis pada epoch akhir baseline merangkum status setiap indikator kesehatan training.

Tabel 4.4. Diagnosis otomatis epoch akhir baseline

Indikator	Nilai	Status
LD	0,718	OK
LG	2,550	OK
Discriminator terlalu yakin	0 epoch	OK
Akurasi classifier	92,33%	OK
Keragaman	0,92	OK
D(real) / D(fake)	0,725 / 0,175	PERHATIAN: D(fake) sedikit di bawah pita sehat 0,2–0,4, tetapi masih di atas batas bahaya 0,1.

Catatan konsistensi. Nilai diagnosis dan nilai baseline pada tabel ablation (LD 0,718; LG 2,550; D(real) 0,725; D(fake) 0,175) sedikit berbeda dari nilai epoch ke-50 pada train_epoch.csv (0,684; 2,610; 0,735; 0,164). Sumber yang tersedia tidak menjelaskan penyebab perbedaan ini, sehingga kedua kelompok angka dilaporkan sesuai sumbernya dan perlu dicocokkan dengan output notebook final.

4.4 Hasil Eksperimen Ablation

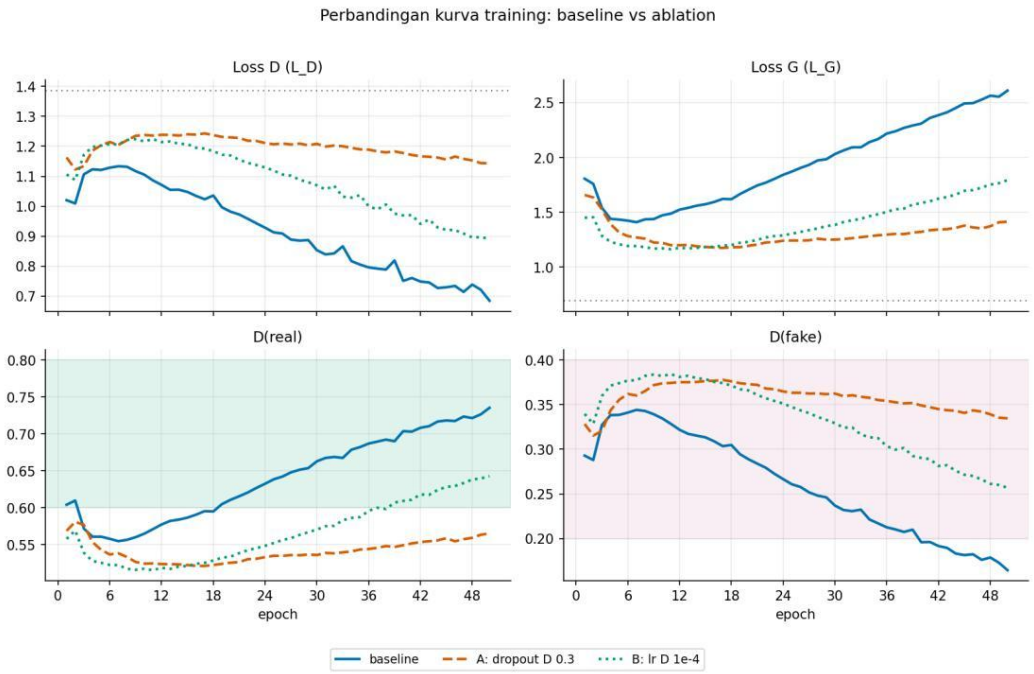
Perbandingan baseline dan kedua eksperimen ablation disajikan pada Tabel 4.5.

Tabel 4.5. Perbandingan baseline dan eksperimen ablation

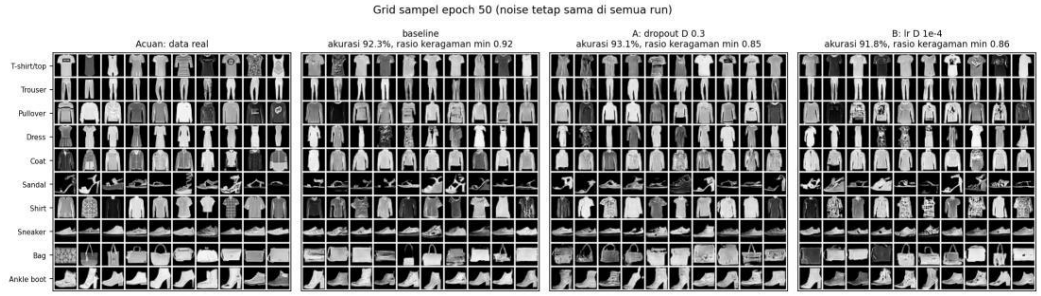
Run	Epoch	Akurasi	Keragaman min.	LD	LG	D(real)	D(fake)
Baseline	50	92,33%	0,918	0,718	2,550	0,725	0,175
A: dropout D 0,3	50	93,14%	0,853	1,153	1,382	0,560	0,339
B: lr D 1e-4	50	91,78%	0,865	0,902	1,747	0,637	0,263

Pada kedua run, D(fake) meningkat dan LG menurun dibanding baseline. Hal ini mendukung interpretasi bahwa Discriminator pada baseline menjadi relatif kuat. Namun, loss yang lebih seimbang tidak otomatis meningkatkan seluruh metrik kualitas. Run A memperoleh akurasi tertinggi (naik 0,81 poin persentase), tetapi rasio keragaman minimumnya turun dari 0,92 menjadi 0,85. Run B memiliki akurasi 91,78% (turun 0,55 poin persentase) dan rasio keragaman minimum 0,86. Dengan demikian, tidak ada satu konfigurasi ablation yang unggul pada seluruh metrik.

Perbandingan kurva training ketiga konfigurasi ditunjukkan pada Gambar 4.7, sedangkan perbandingan grid sampel epoch 50 ditunjukkan pada Gambar 4.8.



Gambar 4.7. Perbandingan kurva training baseline, run A, dan run B.



Gambar 4.8. Perbandingan grid sampel epoch 50 pada data real, baseline, run A, dan run B.

Keterbatasan eksperimen. Setiap konfigurasi hanya dijalankan satu kali dengan satu seed, hanya satu nilai dropout dan satu nilai learning rate Discriminator yang diuji, dan selisih akurasi tergolong kecil. Galat sampling yang dihitung tidak menggantikan pengukuran variasi antar-seed. Oleh sebab itu, hasil ablation diperlakukan sebagai petunjuk, bukan bukti final bahwa salah satu konfigurasi lebih unggul.

4.5 Analisis Hasil

Kenaikan LG bersamaan dengan penurunan LD dapat terjadi karena Discriminator semakin mampu membedakan gambar palsu dari gambar asli. Pada baseline, D(fake) turun menjadi 0,164 pada train_epoch.csv (0,175 pada diagnosis otomatis; lihat Subbab 4.3.5) sehingga Generator menerima penilaian yang lebih rendah dari Discriminator dan nilai loss Generator meningkat. Walaupun demikian, akurasi classifier pada gambar sintetis relatif stabil pada kisaran 92% dari epoch 20 sampai 50. Dengan demikian, loss adversarial dan metrik kesesuaian label mengukur aspek yang berbeda.

Akurasi gambar sintetis epoch 50 sebesar 92,33% sedikit lebih tinggi daripada akurasi data asli 91,32%. Hasil ini berarti classifier pendamping lebih sering memprediksi label yang diminta pada gambar sintetis dalam evaluasi tersebut. Hal ini tidak membuktikan bahwa gambar sintetis lebih baik daripada data asli. Uji keyakinan classifier menghasilkan 0,914 pada data asli dan 0,912 pada gambar sintetis, sehingga dugaan bahwa gambar sintetis lebih prototipikal dan lebih meyakinkan classifier tidak didukung oleh pengujian tersebut. Penyebab selisih akurasi belum dapat dipastikan.

4.6 Pemilihan Checkpoint untuk Demonstrasi

Rekomendasi yang tercatat adalah menggunakan checkpoint baseline epoch 50 (ckpt_epoch050.pt) sebagai model utama demonstrasi generate(). Alasannya, baseline memenuhi target evaluasi, akurasi stabil pada checkpoint akhir, rasio keragaman minimumnya tertinggi dibanding run A dan B, serta menjadi acuan yang konsisten bagi grafik dan pembahasan. Run A dapat ditampilkan sebagai pembanding ablation, bukan otomatis sebagai model utama.

BAB V. AUDIT IMPLEMENTASI DAN BUKTI EKSEKUSI

Bab ini memuat hasil pemeriksaan langsung terhadap tiga berkas notebook (.ipynb) dan arsip hasil yang diserahkan kelompok. Pemeriksaan mencakup struktur cell, kode implementasi, execution count, output yang tersimpan, hasil tes, log training, dan hasil evaluasi. Status yang dilaporkan merujuk pada output yang tertanam di notebook, bukan klaim bahwa seluruh notebook dijalankan ulang pada saat penyusunan dokumen.

5.1 Berkas yang Diperiksa

Notebook yang diperiksa ditunjukkan pada Tabel 5.1, sedangkan arsip hasil eksekusi yang menyertainya ditunjukkan pada Tabel 5.2.

Tabel 5.1. Berkas notebook yang diperiksa

Anggota	Berkas notebook	Cakupan
Anggota 1 – Axel	cGAN_FashionMNIST (1).ipynb	Bagian 0 Setup & Config; Bagian 1 Utils; Bagian 2 Generator.
Anggota 2 – Bianka	cGAN_Dataset_Classifier_ Generate (2).ipynb	Bagian 3 Dataset; Bagian 4 Classifier pendamping dan generate().
Anggota 3 – Alexandra	cGAN_bagian5_8_anggota3 (1).ipynb	Bagian 5 Discriminator; Bagian 6 Training Loop; Bagian 7 Evaluasi; Bagian 8 Ablation.

Tabel 5.2. Arsip hasil eksekusi yang diperiksa

Arsip	Isi yang terverifikasi
figures (ZIP)	Grafik loss, accuracy, diversity, output Discriminator, confusion matrix, dan progres sampel.
logs (ZIP)	CSV training per epoch/iterasi, ringkasan evaluasi, evaluasi per kelas, dan confusion matrix.
runs (ZIP)	Artefak hasil eksperimen A dan B, masing-masing berupa figures dan logs.
ablation (ZIP)	CSV perbandingan baseline/A/B serta grafik kurva dan grid sampel ablation.

5.2 Hasil Pemeriksaan Notebook per Anggota

Hasil pemeriksaan setiap notebook dirangkum pada Tabel 5.3.

Tabel 5.3. Ringkasan hasil pemeriksaan notebook per anggota

Anggota	Bukti output yang ditemukan	Status	Catatan
Axel	Output versi Python/PyTorch; device CUDA Tesla T4; konfigurasi seed 42. TES Bagian 0, TES 1.1–1.4, dan TES 2.1–2.6 lulus. Parameter Generator 1.105.877.	Lulus pada tes yang memiliki output tersimpan.	Generator menghasilkan bentuk [B,1,28,28] dan rentang [−1,1]; pengaruh label diuji dengan z yang sama.
Bianka	Data train 60.000 gambar/468 batch; test 10.000 gambar/79 batch; rentang batch [−1,1]. TES 3.1, 3.2, 4a.1, 4a.2, dan 4b lulus. Akurasi test classifier 91,47%.	Lulus pada tes yang memiliki output tersimpan.	Eksekusi classifier tercatat pada CPU (PyTorch +cpu), sekitar 8,2 menit untuk 5 epoch. Hasil generate() memakai Generator yang belum dilatih, sehingga akurasi 10% pada contoh tersebut bukan hasil evaluasi GAN terlatih.
Alexandra	TES 5, 6, 7, dan 8 lulus; mini-training dan uji resume checkpoint tercatat. Training baseline 50 epoch pada CUDA; evaluasi checkpoint epoch 10–50. Dua eksperimen ablation masing-masing 50 epoch.	Lulus pada tes yang memiliki output tersimpan; baseline dan ablation selesai.	Notebook menyimpan grafik, tabel evaluasi, dan ringkasan metrik. Terdapat RuntimeWarning Matplotlib (lebih dari 20 figure terbuka), tetapi output ablation tetap tercatat.

5.3 Catatan Error dan Peringatan

Pada output ketiga notebook tidak ditemukan output bertipe exception atau traceback yang menunjukkan sel gagal dieksekusi. Pada bagian eksperimen

ablation tercatat RuntimeWarning bahwa lebih dari 20 figure Matplotlib telah dibuka. Peringatan ini berkaitan dengan banyaknya objek grafik yang masih terbuka dan potensi konsumsi memori; output berikutnya tetap menunjukkan TES 8 lulus dan proses eksperimen A/B selesai.

Karena tidak ditemukan traceback kegagalan, dokumen ini tidak mencantumkan error fiktif. Kendala yang terdokumentasi berupa ketidakjelasan spesifikasi, keputusan kompatibilitas antarmodul, kegagalan mount Google Drive yang diperbaiki, perbedaan lingkungan sandbox/CPU dan Colab/T4, penggunaan data tiruan pada smoke test, serta koreksi interpretasi hasil (lihat Subbab 3.5).

5.4 Kesesuaian Implementasi dengan Blueprint

Kesesuaian antara rancangan pada Bab II dan implementasi yang dilaporkan pada notebook dirangkum pada Tabel 5.4. Isi tabel disusun dari spesifikasi pada Bab II dan hasil pengujian pada Bab III dan Bab IV.

Tabel 5.4. Kesesuaian implementasi dengan blueprint

Aspek blueprint	Implementasi yang dilaporkan	Dasar pelaporan
Bentuk implementasi	Satu notebook Colab dengan Bagian 0–8, bukan berkas .py terpisah.	Subbab 3.1.2 dan Tabel 3.5
Generator	Keluaran [B,1,28,28] pada [−1,1]; 1.105.877 parameter; label memengaruhi keluaran.	Tabel 3.1
Dataset	Tensor [B,1,28,28] float32 pada [−1,1] dan label int64 0–9; 468 batch per epoch.	Subbab 3.2.1 dan Sesi 2.2 (Lampiran A)
Discriminator	Logit [B] tanpa Sigmoid; 440.801 parameter.	Tabel 3.3
Training loop	Target 0,9/0,0/1,0; dua optimizer Adam; checkpoint, log CSV, dan resume.	Subbab 3.3.2
Evaluasi	Akurasi classifier, rasio keragaman, kurva, dan grid dari berkas log.	Subbab 3.3.3 dan Bab IV
Ablation	Run A (d_dropout 0,3) dan run B (lr_d 1e-4), satu perubahan per run.	Tabel 3.4 dan Tabel 4.5

5.5 Verifikasi Hasil Eksperimen

Hasil training dan evaluasi pada Bab IV bersumber dari berkas log dan grafik pada arsip hasil eksekusi (Tabel 5.2). Grafik dibuat dari berkas log atau CSV, bukan dari angka yang diketik manual (Subbab 3.3.3). Nilai epoch akhir pada train_epoch.csv dan nilai pada tabel diagnosis serta tabel ablation memiliki selisih kecil yang penyebabnya belum terverifikasi (Subbab 4.3.5); kedua kelompok angka dilaporkan sesuai sumbernya.

5.6 Catatan Konsistensi dan Batas Bukti

- **Dua angka akurasi classifier.** Angka 91,47% berasal dari notebook Bianka, sedangkan 91,32% tercatat sebagai akurasi classifier pada data asli di notebook evaluasi Alexandra. Keduanya dilaporkan sesuai sumber masing-masing dan tidak digabungkan.
- **Perbedaan lingkungan eksekusi.** Notebook Bianka menyimpan output eksekusi pada CPU, sedangkan notebook Axel serta bagian training dan evaluasi Alexandra menyimpan output CUDA/Tesla T4. Hal ini tidak berarti semua bagian dijalankan pada perangkat yang sama.
- **Cell awal notebook Bianka.** Tercatat pesan bahwa direktori GEN_AI sudah ada dan tidak kosong, serta peringatan runtime CPU. Cell dataset dan classifier berikutnya tetap memiliki output tes LULUS dan metrik evaluasi.
- **Uji mini-training.** Notebook Alexandra memuat output uji mini-training 3 epoch dan 2 epoch dengan metrik rendah. Output tersebut adalah uji fungsi sebelum training penuh, bukan hasil baseline final.
- **Perbedaan nilai epoch akhir.** Nilai diagnosis dan tabel ablation sedikit berbeda dari nilai epoch ke-50 pada train_epoch.csv (lihat catatan pada Subbab 4.3.5); penyebabnya belum terverifikasi.
- **Output notebook bukan tangkapan layar UI.** Output notebook mendukung pelaporan proses eksekusi, tetapi bukan screenshot antarmuka Google Colab. Jika dosen secara eksplisit meminta screenshot UI Colab, screenshot tersebut tetap perlu disisipkan terpisah.

5.7 Kesimpulan Audit

Berdasarkan tiga notebook yang diperiksa, bagian implementasi Anggota 1 sampai Anggota 3 memiliki kode dan output eksekusi yang tersimpan. Tes yang ditandai LULUS memiliki output pendukung. Notebook Anggota 3 juga memuat hasil training baseline 50 epoch, evaluasi lima checkpoint, serta dua eksperimen ablation. Dengan demikian, dokumentasi dapat menyatakan bahwa bukti kode dan output notebook telah tersedia. Klaim mengenai screenshot antarmuka Colab harus dibatasi, karena berkas yang diperiksa adalah notebook dengan output tertanam, bukan screenshot UI terpisah.

BAB VI. KESIMPULAN DAN SARAN

6.1 Kesimpulan Proyek

Kelompok berhasil membangun dan menjalankan cGAN bergaya DCGAN untuk Fashion-MNIST menggunakan PyTorch dalam satu notebook Colab. Pembagian kerja berbasis kontrak tensor memungkinkan anggota mengembangkan bagian yang berbeda dengan antarmuka yang saling kompatibel. Baseline 50 epoch dilaporkan selesai pada GPU T4 tanpa error.

Evaluasi baseline menunjukkan akurasi classifier pada gambar sintetis sebesar 92,33%, akurasi data asli 91,32%, serta rasio keragaman minimum 0,92. Hasil tersebut menunjukkan model mampu menghasilkan gambar yang cukup konsisten dengan label yang diminta menurut classifier pendamping dan tidak menunjukkan penurunan keragaman di bawah ambang proyek. Namun, metrik tersebut tidak membuktikan bahwa gambar sintetis lebih baik daripada gambar asli.

Dua eksperimen ablation memperlihatkan bahwa melemahkan Discriminator meningkatkan D(fake) dan menurunkan LG, tetapi tidak menghasilkan peningkatan menyeluruh pada akurasi dan keragaman. Dengan keterbatasan satu seed per run, baseline dipertahankan sebagai checkpoint utama demonstrasi.

Audit terhadap tiga notebook menunjukkan bahwa kode dan output eksekusi tersedia untuk seluruh bagian implementasi. Dokumentasi Vibe Coding ini memperlihatkan bahwa LLM digunakan sebagai alat bantu perencanaan, implementasi, pengujian, dan analisis, sementara keputusan akhir tetap dikonfirmasi melalui pengujian dan pertimbangan kelompok.

6.2 Keterbatasan

- Eksperimen ablation hanya menggunakan satu seed untuk setiap konfigurasi.
- Hanya satu nilai dropout (0,3) dan satu nilai learning rate Discriminator (1e-4) yang diuji; hal ini belum merupakan pencarian hyperparameter menyeluruh.
- Akurasi classifier pendamping mengukur kesesuaian label dan kemudahan klasifikasi, bukan kualitas visual secara menyeluruh atau kemiripan distribusi secara lengkap.

- Penyebab akurasi sintetis yang sedikit lebih tinggi dibanding data asli belum dibuktikan.
- Rasio keragaman berbasis variasi piksel tidak cukup untuk menyimpulkan seluruh aspek keragaman semantik.
- Sebagian pengujian awal di sandbox memakai data pengganti; klaim hasil pada dataset asli harus didasarkan pada eksekusi Colab.

6.3 Saran Pengembangan

Berdasarkan keterbatasan yang telah diuraikan, saran untuk pengembangan selanjutnya adalah sebagai berikut.

- Menjalankan setiap konfigurasi dengan beberapa seed dan melaporkan variasi antar-seed sebelum menyimpulkan keunggulan suatu konfigurasi.
- Menguji lebih banyak nilai dropout dan learning rate Discriminator, serta opsi stabilisasi lain yang telah tersedia pada implementasi, seperti spectral norm.
- Melengkapi evaluasi dengan metrik kualitas dan keragaman selain akurasi classifier pendamping dan variasi piksel, disertai pemeriksaan visual.
- Menelusuri penyebab selisih nilai epoch akhir antara train_epoch.csv dan tabel diagnosis atau ablation, lalu mencocokkannya dengan output notebook final.
- Menutup objek figure Matplotlib setelah digunakan agar peringatan lebih dari 20 figure terbuka pada eksperimen ablation tidak muncul.
- Melengkapi bukti pendukung sebagaimana tercantum pada Lampiran B, termasuk tangkapan layar antarmuka Colab apabila diminta.

LAMPIRAN A. LOG INTERAKSI VIBE CODING PER SESI

Lampiran ini menyajikan log interaksi per sesi sesuai template panduan. Satu sesi adalah satu rangkaian prompt dengan satu target modul. Kolom Tautan Sesi Chat merujuk pada tautan berbagi di Lampiran B; beberapa sesi berada dalam satu percakapan yang sama sehingga tautannya sama. Prompt yang panjang diringkas tanpa mengubah tujuan teknisnya. Tabel A.1 (urutan pengerjaan dan serah-terima antaranggota) disajikan pada akhir lampiran ini.

A.1 Anggota 1: Axel (Prompt Engineer)

Sesi 1.1: Analisis pemilihan model

Komponen	Isi
Tanggal Sesi	1 November 2026
Target Modul	Perbandingan enam kandidat model dan pemilihan model proyek
Tautan Sesi Chat	Lampiran B, nomor 1 (Axel)
Tahap Inisiasi: Prompt Kelompok	“Buat analisis perbandingan enam kandidat model generatif: Conditional GAN, Pix2Pix, CycleGAN, Vision Transformer minimalis, Mini Diffusion Model, dan Mini-Transformer GPT. Bandingkan kebutuhan dataset, kesulitan implementasi dari nol, estimasi training di GPU T4, risiko, kemudahan presentasi, dan pembagian empat peran.”
Tahap Inisiasi: Alasan Khusus	Sisa waktu pengerjaan sekitar tiga hari, GPU Colab T4 gratis, dan proyek harus dapat dibagi kepada empat anggota serta mudah dipresentasikan.
Tahap Inisiasi: Output Model	Rekomendasi Conditional GAN pada Fashion-MNIST. Risiko utama: mode collapse atau ketidakseimbangan G–D, dan kurva loss GAN yang tidak selalu menurun. Mitigasi: arsitektur DCGAN, Adam, one-sided label smoothing, checkpoint, grid sampel berkala, metrik D(real)/D(fake), dan classifier pendamping.
Tahap Penanganan Eror	Tidak ada eror pada sesi ini.

Sesi 1.2: Penyusunan cetak biru

Komponen	Isi
Tanggal Sesi	29 Oktober 2026
Target Modul	Cetak biru teknis Conditional GAN
Tautan Sesi Chat	Lampiran B, nomor 1 (Axel)
Tahap Inisiasi: Prompt Kelompok	"Susun cetak biru Conditional GAN untuk Fashion-MNIST dari nol dengan PyTorch. Jabarkan preprocessing, arsitektur Generator dan Discriminator, formulasi loss, hyperparameter, stabilisasi, evaluasi, alur generate, dan risiko."
Tahap Inisiasi: Alasan Khusus	Cetak biru menjadi acuan tunggal dan menetapkan kontrak tensor antarbagian, sehingga empat anggota dapat bekerja paralel tanpa menunggu bagian lain.
Tahap Inisiasi: Output Model	Cetak biru dengan kontrak antarmuka Bagian 0–8, dataset, arsitektur, loss, hyperparameter, evaluasi, dan risiko.
Tahap Penanganan Eror (sri)	Kendala: rancangan awal memakai berkas .py terpisah, sedangkan tim memilih satu notebook Colab. Penanganan: cetak biru direvisi agar pembagian kerja berbasis Bagian notebook dan kontrak tensor.

Sesi 1.3: Bagian 0 dan 1 (Setup & Config, Utils)

Komponen	Isi
Tanggal Sesi	29 Oktober 2026
Target Modul	Bagian 0 (Setup & Config) dan Bagian 1 (Utils)
Tautan Sesi Chat	Lampiran B, nomor 1 (Axel)
Tahap Inisiasi: Prompt Kelompok	"Buat Bagian 0 dan 1 sesuai cetak biru: import, seed, device, seluruh hyperparameter dalam satu konfigurasi; kemudian weight initialization, penyimpanan grid gambar dengan denormalisasi, serta simpan/muat checkpoint ke Google Drive. Jelaskan konsep, alasan desain, kode, cara tes, dan pertanyaan yang mungkin diajukan dosen."
Tahap Inisiasi: Alasan Khusus	Seluruh hyperparameter dikumpulkan di satu konfigurasi agar bagian lain membacanya dari sumber yang sama. Checkpoint disimpan ke Google Drive supaya tahan terhadap sesi Colab yang terputus.

Komponen	Isi
Tahap Inisiasi: Output Model	Notebook Bagian 0–1 yang lulus tes lokal. Utilitas: `make_fixed_noise`, `ckpt_path`, `latest_checkpoint`, penyimpanan checkpoint secara atomik, dan fallback ke folder lokal bila Drive tidak tersedia.
Tahap Penanganan Eror (sri)	Kendala: tes lokal berjalan di CPU sehingga GPU T4 dan mount Google Drive belum teruji. Penanganan: notebook dijalankan di Colab; Bagian 0–1 lulus pada T4 dan Drive terhubung ke `/content/drive/MyDrive/cgan_fashion_mnist`.

Sesi 1.4: Bagian 2 (Generator)

Komponen	Isi
Tanggal Sesi	29 Oktober 2026
Target Modul	Bagian 2 (Generator)
Tautan Sesi Chat	Lampiran B, nomor 1 (Axel)
Tahap Inisiasi: Prompt Kelompok	“Implementasikan Generator sesuai cetak biru. Ukuran layer harus dibaca dari CFG; gunakan weights_init; uji output [B,1,28,28] dalam rentang [−1,1], jumlah parameter sekitar 1,1 juta, pengaruh label terhadap output, batch satu sampel dalam mode eval, dan grid fixed-noise.”
Tahap Inisiasi: Alasan Khusus	Ukuran layer dibaca dari CFG agar tidak ada angka yang ditulis langsung di kode. Tes dirancang agar kesalahan yang sengaja ditanam dapat terdeteksi.
Tahap Inisiasi: Output Model	Generator dengan embedding label yang digabung dengan noise, resolusi 7×7 dinaikkan lewat ConvTranspose2d hingga 28×28, keluaran Tanh. Parameter 1.105.877; TES 2.1–2.6 lulus; tes dijalankan dengan 20 seed dan bug yang sengaja ditanam.
Tahap Penanganan Eror (sri)	Kendala: Generator yang belum dilatih menghasilkan gambar abu-abu rata dalam mode eval. Penanganan: dijelaskan sebagai efek statistik BatchNorm yang belum terbentuk, bukan kerusakan model.

A.2 Anggota 2: Bianka (Data Pipeline)

Sesi 2.1: Konfirmasi kontrak Bagian 3–4

Komponen	Isi
Tanggal Sesi	30 Oktober 2026
Target Modul	Pemahaman kontrak Bagian 3 (Dataset) dan Bagian 4 (Classifier + generate)
Tautan Sesi Chat	Lampiran B, nomor 2 (Bianka)
Tahap Inisiasi: Prompt Kelompok	LLM diminta bertindak sebagai Senior Machine Learning Engineer sekaligus mentor. Notebook tim (Bagian 0–2) dan cetak biru dilampirkan. Standar kode: pola Konsep → Kode → Tes; tidak ada angka hard-coded; setiap sel aman dijalankan ulang; kode dapat dipindah ke notebook utama tanpa modifikasi; tidak menyalin dari tutorial. Instruksi akhir: "konfirmasi pemahaman Anda atas konteks dan kontrak Bagian 3 dan 4 dalam maksimal 10 poin, lalu tunggu instruksi berikutnya."
Tahap Inisiasi: Alasan Khusus	Objek tim (CFG, DEVICE, Generator, utilitas) wajib dipakai ulang, sehingga kontrak perlu dipastikan sebelum kode ditulis. Kelanjutan ke sub-bagian berikutnya hanya setelah tes dikonfirmasi lulus.
Tahap Inisiasi: Output Model	Ringkasan kontrak `get_dataloader` dan classifier, serta tiga celah yang perlu diputuskan: padding classifier, argumen `train`, dan parameter config baru. Keputusan: `padding=1`, `get_dataloader(batch_size, train=True)`, dan `ClassifierConfig`/`CLF_CFG` terpisah.
Tahap Penanganan Eror (sri)	Kendala: cetak biru tidak menyebut padding convolution classifier, dan CFG milik ketua tidak boleh diubah. Penanganan: dipilih `padding=1` agar resolusi 28→14→7 (flatten 3136) dan dibuat dataclass terpisah.

Sesi 2.2: Bagian 3.1 (get_dataloader)

Komponen	Isi
Tanggal Sesi	30 Oktober 2026
Target Modul	Bagian 3.1: DataLoader Fashion-MNIST
Tautan Sesi Chat	Lampiran B, nomor 2 (Bianka)

Komponen	Isi
Tahap Inisiasi: Prompt Kelompok	“Silakan mulai dari sub-bagian 3.1 sesuai format yang disepakati: Konsep → Kode → Tes.” (disertai keputusan padding, argumen `train`, dan `ClassifierConfig` terpisah).
Tahap Inisiasi: Alasan Khusus	Normalisasi ke [−1, 1] menyamakan skala dengan keluaran Tanh Generator. `drop_last=True` pada train menjaga statistik BatchNorm stabil dan menetapkan 468 batch per epoch. Shuffle memakai generator berseed sendiri agar urutan dapat direproduksi.
Tahap Inisiasi: Output Model	`get_dataloader`, `build_transform`, dan tes kontrak. Hasil di Colab: train 60.000 gambar/468 batch, test 10.000 gambar/79 batch, rentang batch [−1,0000, 1,0000]; TES 3.1 LULUS.
Tahap Penanganan Eror (sri)	Kendala: sandbox LLM tidak dapat mengunduh Fashion-MNIST sehingga tes awal memakai file pengganti. Penanganan: seluruh tes dijalankan ulang di Colab dengan data asli dan lulus.

Sesi 2.3: Bagian 3.2 (pemeriksaan visual data)

Komponen	Isi
Tanggal Sesi	30 Oktober 2026
Target Modul	Bagian 3.2: grid 16 gambar real berlabel dan grid acuan 10×10
Tautan Sesi Chat	Lampiran B, nomor 2 (Bianka)
Tahap Inisiasi: Prompt Kelompok	“Silakan lanjut ke sub-bagian 3.2 (pemeriksaan visual grid 16 gambar asli berlabel) dengan format yang sama: Konsep → Kode → Tes. Gunakan ulang denormalize dan helper tampilan dari Bagian 1 bila memungkinkan.”
Tahap Inisiasi: Alasan Khusus	Tes otomatis tidak dapat membuktikan bahwa gambar dan labelnya berpasangan dengan benar; cetak biru mewajibkan pemeriksaan manual sebelum training. Skala warna dikunci pada [0, 1] agar bug normalisasi tidak tersembunyi.
Tahap Inisiasi: Output Model	`PreviewConfig`, `show_labeled_images`, dan `real_reference.png`. TES 3.2 LULUS. Cek manual: label sesuai isi, orientasi tegak, kontras wajar, grid acuan rapi (satu sampel Shirt tampak mirip dress).

Komponen	Isi
Tahap Penanganan Eror (sri)	Eror: mount Google Drive gagal (“credential propagation was unsuccessful”) sehingga keluaran tersimpan di `./outputs`. Penanganan: ditambahkan sel `drive.mount()` di awal notebook; keluaran kini di `/content/drive/MyDrive/cgan_fashion_mnist` dan grid acuan ada di `samples/real_reference.png`.

Sesi 2.4: Bagian 4a (classifier pendamping)

Komponen	Isi
Tanggal Sesi	30 Oktober 2026
Target Modul	Bagian 4a: classifier pendamping
Tautan Sesi Chat	Lampiran B, nomor 2 (Bianka)
Tahap Inisiasi: Prompt Kelompok	“Bagian 3 selesai. Silakan lanjut ke Bagian 4a: Classifier Pendamping.” Spesifikasi: Conv(1→32)–ReLU–MaxPool, Conv(32→64)–ReLU–MaxPool, Flatten, Linear(3136→128), Linear(128→10); Adam lr 1e-3, batch 128, 5 epoch pada data asli; deliverable `ClassifierConfig`, `Classifier`, fungsi training, `evaluate_classifier`, `load_classifier`, dan mekanisme lewati-training.
Tahap Inisiasi: Alasan Khusus	Classifier adalah alat ukur independen untuk Bagian 7, dilatih sekali pada data asli lalu dibekukan agar pengukuran tidak berubah antarsesi. Nama berkas `classifier.pt` sengaja tidak berawalan `ckpt_epoch` agar tidak tertukar dengan checkpoint GAN.
Tahap Inisiasi: Output Model	Classifier beserta fungsi training, evaluasi, simpan–muat, dan lewati-training. TES 4a.1 dan 4a.2 LULUS. Akurasi test 91,47%; kelas terendah Shirt 76,40%, tertinggi Trouser 98,70%.

Komponen	Isi
Tahap Penanganan Eror	Kendala 1: daftar tes pada prompt terpotong setelah poin kedua. Penanganan: LLM melengkapi dan menandai tes tambahan (konsistensi evaluasi, status beku, muat ulang identik, lewati-training, penolakan config tidak cocok). Kendala 2: training di CPU Colab 97,5–101,3 detik per epoch (total 8,2 menit), lebih lambat dari estimasi 2–5 menit. Penanganan: dipertahankan; mekanisme lewati-training mencegah pelatihan ulang.

Sesi 2.5: Bagian 4b (fungsi generate) dan materi serah-terima

Komponen	Isi
Tanggal Sesi	30 Oktober 2026
Target Modul	Bagian 4b: `generate(checkpoint_path, class_id, n)` dan serah-terima ke Bagian 5–7
Tautan Sesi Chat	Lampiran B, nomor 2 (Bianka)
Tahap Inisiasi: Prompt Kelompok	"Silakan lanjut ke Bagian 4b: fungsi generate." Spesifikasi: muat checkpoint dengan `load_checkpoint`, bangun Generator dan set `eval()`, buat z dan y di device yang sama, hasilkan di bawah `torch.no_grad()`; validasi config checkpoint, `ValueError` untuk `class_id`/`n` tidak valid, parameter `seed` opsional, dan `generate_all_classes`. Setelah itu diminta ringkasan 2 menit, 5 pertanyaan dosen, tabel serah-terima, dan kronologi sesi.
Tahap Inisiasi: Alasan Khusus	Bagian 7 memerlukan 10 kelas × 1.000 gambar, sehingga pemuatan checkpoint dipisah (`load_generator`, `sample_from_generator`) agar dibaca sekali. `G.eval()` wajib karena BatchNorm, dan seed opsional membuat demo presentasi dapat diulang.
Tahap Inisiasi: Output Model	`load_generator`, `sample_from_generator`, `generate`, dan `generate_all_classes`. TES 4b LULUS. Pada Generator yang belum dilatih, akurasi classifier 10,00% (semua diprediksi "Bag"), sesuai perkiraan. Materi penutup dibuat sebagai dokumen serah-terima.
Tahap Penanganan Eror	Tidak ada eror. Catatan: gambar noise dan akurasi 10% adalah keluaran yang diharapkan dari Generator yang belum dilatih, bukan hasil akhir model.

A.3 Anggota 3: Alexandra (Discriminator, Training Loop, Evaluasi, Ablation)

Sesi 3.1: Bagian 5 (Discriminator)

Komponen	Isi
Tanggal Sesi	1 November 2026
Target Modul	Bagian 5: Discriminator
Tautan Sesi Chat	Lampiran B, nomor 3 (Alexandra)
Tahap Inisiasi: Prompt Kelompok	"Mulai dengan Bagian 5: Discriminator D(x [B,1,28,28], y [B]) yang menghasilkan logit [B] tanpa Sigmoid. Label diubah lewat nn.Embedding(10, 784), di-reshape ke 1x28x28, lalu di-concat ke gambar. Ikuti tabel layer di cetak biru, inisialisasi N(0, 0,02), dan sediakan opsi dropout dan spectral_norm (default mati)." Tes yang diminta: bentuk keluaran, jumlah parameter (±0,44 juta), dan pasangan (gambar, label salah) harus memberi logit berbeda.
Tahap Inisiasi: Alasan Khusus	Tanpa Sigmoid karena `BCEWithLogitsLoss` sudah memuatnya. Discriminator dibuat lebih kecil daripada Generator agar tidak menang terlalu cepat. Dropout dan spectral norm disediakan sebagai cadangan stabilisasi untuk Bagian 6.
Tahap Inisiasi: Output Model	Discriminator 440.801 parameter. TES 5 LULUS di Colab: selisih logit benar/salah minimum 2,35e-04 dan rata-rata 1,01e-02; mini-training 150 langkah menilai pasangan benar lebih tinggi pada 100% pasangan.
Tahap Penanganan Eror (sri)	Kendala 1: pemasangan PyTorch di sandbox LLM memakan waktu lama, sehingga tes awal memakai data acak. Penanganan: tes dijalankan di Colab (GPU) dan lulus. Kendala 2: tiga hal tidak ditetapkan cetak biru. Penanganan: ditanyakan lebih dulu lalu disetujui: embedding memakai inisialisasi default PyTorch, konvolusi mode spectral norm diberi bias, dan `D.apply(weights_init)` tidak dipanggil ulang di Bagian 6.

Sesi 3.2: Bagian 6 (training loop)

Komponen	Isi
Tanggal Sesi	1 November 2026
Target Modul	Bagian 6: training loop 50 epoch
Tautan Sesi Chat	Lampiran B, nomor 3 (Alexandra)
Tahap Inisiasi: Prompt Kelompok	"Lanjut ke Bagian 6: training loop 50 epoch sesuai cetak biru. Ketentuannya: BCEWithLogitsLoss, target real 0,9, target fake 0,0, target G 1,0, Adam lr 2e-4 betas (0,5; 0,999) untuk G dan D (dua optimizer terpisah), satu langkah D lalu satu langkah G per iterasi. Di langkah D, pakai .detach() pada gambar fake. Simpan checkpoint tiap 10 epoch dan di akhir, log CSV per iterasi, grid sampel 10x10 tiap 5 epoch, fungsi resume, dan tes awal dengan epoch kecil."
Tahap Inisiasi: Alasan Khusus	Target real 0,9 menjaga Discriminator agar tidak terlalu yakin, karena Discriminator yang terlalu yakin mematikan gradien ke Generator. `.detach()` mencegah langkah D mengubah Generator. Run ablation wajib memakai folder sendiri agar baseline tidak tertimpa.
Tahap Inisiasi: Output Model	`d_step`, `g_step`, `train_iteration`, `train`, serta log, grid sampel, dan resume. TES 6 LULUS (detach, pemisahan optimizer, rumus loss, smoke test, resume). Baseline 50 epoch selesai di Colab T4, sekitar 18 detik per epoch (±15 menit).
Tahap Penanganan Eror (sri)	Temuan 1: iterasi pertama memberi L_D 1,68 dan D(real) 0,35, berbeda dari acuan 1,386 dan 0,693. Penanganan: dijelaskan sebagai efek BatchNorm Discriminator pada mode train; acuan berlaku saat seimbang. Temuan 2: `load_state_dict` membawa learning rate lama saat resume. Penanganan: learning rate optimizer ditimpa dari CFG agar perubahan `lr_d` berlaku.

Sesi 3.3: Bagian 7 (evaluasi)

Komponen	Isi
Tanggal Sesi	1 November 2026
Target Modul	Bagian 7: kurva loss, D(real) vs D(fake), akurasi classifier, dan keragaman

Komponen	Isi
Tautan Sesi Chat	Lampiran B, nomor 3 (Alexandra)
Tahap Inisiasi: Prompt Kelompok	"Lanjut Bagian 7 (evaluasi) sesuai cetak biru: kurva loss G dan D dengan garis acuan 1,386 dan 0,693 (dari train_ epoch.csv dan train_iter.csv), grafik D(real) vs D(fake), akurasi classifier pada 1.000 gambar buatan per kelas lewat generate() (checkpoint epoch 10, 20, 30, 40, 50, target total ≥ 80%, bandingkan dengan akurasi pada data asli), dan keragaman per kelas (rasio buatan/real, ambang 0,5). Semua grafik dari file log."
Tahap Inisiasi: Alasan Khusus	Seluruh grafik dibuat dari berkas log agar angka dapat ditelusuri. Seed evaluasi sengaja dibuat berbeda dari seed grid (`CFG.seed + 1`) agar Generator tidak diuji dengan noise yang sama dengan grid.
Tahap Inisiasi: Output Model	Notebook lima sel dengan enam grafik dan diagnosis otomatis. Hasil di Colab: akurasi gambar buatan 91,75%, 92,32%, 92,30%, 92,13%, 92,33% (data asli 91,32%); rasio keragaman minimum 0,86, 0,83, 0,89, 0,87, 0,92 (kelas Trouser). Diagnosis: semua OK kecuali D(real)/D(fake) 0,725/0,175 berstatus PERHATIAN. TES 7 LULUS.
Tahap Penanganan Eror (sri)	Kendala: sandbox LLM tidak dapat mengunduh Fashion-MNIST, sehingga tes awal memakai data tiruan. Penanganan: angka akurasi dan keragaman diambil dari eksekusi di Colab. Tidak ada traceback pada sesi ini.

Sesi 3.4: Bagian 8 (ablation)

Komponen	Isi
Tanggal Sesi	1 November 2026
Target Modul	Bagian 8: eksperimen ablation dropout dan learning rate Discriminator
Tautan Sesi Chat	Lampiran B, nomor 3 (Alexandra)

Komponen	Isi
Tahap Inisiasi: Prompt Kelompok	Hasil evaluasi baseline dilaporkan, lalu diminta: (1) penjelasan sederhana mengapa L_G naik dan L_D turun padahal akurasi bagus, serta mengapa akurasi gambar buatan (92,33%) sedikit di atas data asli (91,32%); (2) "kode eksperimen tuning/ablation sesuai cetak biru bagian 6 dan 9, satu perubahan per run, tiap run di folder sendiri lewat run_dirs: (A) CFG.d_dropout = 0,3; (B) CFG.lr_d = 1e-4", dikembalikan ke baseline setelah selesai dan dievaluasi dengan `evaluate_all`; (3) satu sel perbandingan baseline, A, dan B.
Tahap Inisiasi: Alasan Khusus	Baseline sudah memenuhi target, sehingga A dan B adalah ablation pembanding, bukan perbaikan darurat. Satu perubahan per run, folder terpisah, dan kriteria penilaian ditetapkan sebelum run dijalankan. Hasil "tidak berbeda dari baseline" diperlakukan sebagai temuan yang sah.
Tahap Inisiasi: Output Model	Mesin eksperimen (`run_ablation`, `cfg_override`), TES 8, dan sel perbandingan. Hasil epoch 50: baseline akurasi 92,33%; A (dropout 0,3) 93,14%, keragaman minimum 0,85, D(fake) 0,339; B (lr_d 1e-4) 91,78%, keragaman minimum 0,86, D(fake) 0,263. Kedua run selesai di Colab.
Tahap Penanganan Eror (sri)	Peringatan: RuntimeWarning Matplotlib karena lebih dari 20 figure terbuka. Penanganan: run A dan B serta TES 8 tetap selesai; penutupan figure dengan `plt.close` dicatat sebagai saran perbaikan (Subbab 6.3).

Sesi 3.5: Interpretasi hasil dan pemilihan checkpoint

Komponen	Isi
Tanggal Sesi	1 November 2026
Target Modul	Kesimpulan ablation untuk presentasi dan pemilihan checkpoint demo
Tautan Sesi Chat	Lampiran B, nomor 3 (Alexandra)

Komponen	Isi
Tahap Inisiasi: Prompt Kelompok	Hasil run A dan B dilaporkan beserta uji keyakinan classifier (real 0,914 vs buatan 0,912). Diminta: (1) perbarui penjelasan akurasi buatan di atas data asli dan jujur bahwa penyebabnya belum terbukti; (2) kesimpulan ablation dengan bahasa sederhana dan jujur soal keterbatasan (satu seed per run, selisih kecil); (3) saran checkpoint untuk demo `generate()` tanpa menulis kode.
Tahap Inisiasi: Alasan Khusus	Kesimpulan untuk presentasi harus jujur terhadap keterbatasan agar klaim tidak melebihi bukti.
Tahap Inisiasi: Output Model	Kesimpulan: memperlemah Discriminator menggeser D(fake) naik dan L_G turun, tetapi kualitas sampel tidak jelas lebih baik; baseline cukup. Rekomendasi demo: baseline epoch 50 (`ckpt_epoch050.pt`), dengan run A sebagai pembanding.
Tahap Penanganan Eror	Koreksi: penjelasan awal bahwa gambar buatan lebih "prototipikal" didukung selisih kelas Shirt, tetapi tidak didukung uji keyakinan (0,914 vs 0,912). Penanganan: paragraf diganti; penyebab selisih akurasi dinyatakan belum terbukti. Catatan terbuka: nilai epoch 50 pada `train_epoch.csv` (0,684; 2,610; 0,735; 0,164) sedikit berbeda dari tabel diagnosis dan ablation (0,718; 2,550; 0,725; 0,175); penyebabnya belum terverifikasi.

A.4 Kronologi Lintas Anggota

Tabel A.1. Urutan pengerjaan dan serah-terima antaranggota

Urutan	Pemilik	Tahapan	Serah-terima utama
1	Axel (Anggota 1)	Pemilihan model → blueprint → Bagian 0–2	CFG, utilitas, Generator, kontrak tensor dan checkpoint.
2	Bianka (Anggota 2)	Bagian 3.1–3.2 → Bagian 4a–4b	DataLoader, classifier beku, generate(), format gambar/label untuk Alexandra.
3	Alexandra (Anggota 3)	Bagian 5–7 → ablation	Discriminator, training, log/checkpoint, evaluasi, eksperimen pembanding.

Urutan	Pemilik	Tahapan	Serah-terima utama
4	Sri (Dokumentasi)	Menggabungkan blueprint, log interaksi, kode, grafik, dan hasil	Laporan proyek dan bukti proses Vibe Coding.

A.5 Status Kelengkapan Log

- Seluruh sesi tiga anggota pengembang telah dicatat dalam format per sesi sesuai template panduan.
- Tanggal sesi dan tautan per sesi mengacu pada tautan berbagi di Lampiran B; kolom bertanda dari tanggal 29 Oktober – 1 November
- Tidak ada traceback fatal pada sumber yang tersedia. Kendala yang terdokumentasi mencakup mount Google Drive yang gagal, runtime CPU yang lebih lambat dari estimasi, daftar tes yang terpotong, perbedaan sandbox dan Colab, serta RuntimeWarning Matplotlib.

LAMPIRAN B. DAFTAR BUKTI PENDUKUNG

Tabel B.1. Tautan sesi chat LLM dan repositori

No	Bukti	Pemilik	Tautan
1	Sesi chat LLM: Sesi 1.1 sampai 1.4	Axel (Anggota 1)	https://claude.ai/share/cafbed27-66de-4cb7-8b5a-9d39fb63cb9b
2	Sesi chat LLM: Sesi 2.1 sampai 2.5	Bianka (Anggota 2)	https://claude.ai/share/2599a9da-ce91-49e8-8d47-9eafbd1dc99c
3	Sesi chat LLM: Sesi 3.1 sampai 3.5	Alexandra (Anggota 3)	https://claude.ai/share/1fe63fe5-296f-47bd-9304-fc954e734c02
4	Sesi chat analisis pemilihan model (Sesi 1.1)	Axel (Anggota 1)	https://claude.ai/share/cafbed27-66de-4cb7-8b5a-9d39fb63cb9b
5	Sesi chat cetak biru (Sesi 1.2)	Axel (Anggota 1)	https://claude.ai/share/cafbed27-66de-4cb7-8b5a-9d39fb63cb9b
6	Repositori GitHub kelompok	Kelompok 4	https://github.com/sridewisn/GEN_AI

Tabel B.2. Bukti tambahan yang dapat dilampirkan

No	Bukti	Keterangan
1	Tangkapan layar halaman utama repositori dan riwayat commit	Gambar 3.1 dan 3.2 pada Subbab 3.6
2	Berkas notebook (.ipynb) dan arsip figures, logs, runs, ablation	Tersedia di repositori GitHub